creative commons

COMMONS DEED

저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:

저작자표시. 귀하는 원저작자를 표시하여야 합니다.

비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.

변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 이용허락규약(Legal Code)을 이해하기 쉽게 요약한 것입니다.

Disclaimer

dCollection

경북대학교 간호학박사학위논문

기계학습에 기반한 급성기 뇌졸중 입원환자의 낙상위험 예측

대학원 간호학과 간호학전공

최 준 화

2022년 12월

경북대학교 대학원

기계학습에 기반한 급성기 뇌졸중 입원환자의 낙상위험 예측

이 논문을 간호학박사 학위논문으로 제출함

대학원 간호학과 간호학전공

최 준 화

지도교수 최 은 숙

최준화의 간호학박사 학위논문을 인준함

2022년 12월

위원장 _____ ㊞

_____ ㊞

_____ ㊞

_____ ㊞

_____ ㊞

경북대학교 대학원위원회

목 차

서론 ····· 1
연구의 필요성 ····· 1
연구목적 ····· 5

용어의 정의 ····· 6
급성기 뇌졸중 입원환자 ····· 6
낙상 ····· 6
낙상위험도 ····· 6
낙상위험요인 ····· 7
기계학습 알고리즘 ····· 7

문헌고찰 ····· 8
급성기 뇌졸중 입원환자의 낙상 ····· 8
낙상위험도 ····· 8
낙상위험요인 ····· 9
기계학습 알고리즘 ····· 15

연구의 개념적 틀 ····· 23
본 연구의 개념적 틀 ····· 23

연구방법 ····· 26
연구설계 ····· 26

자료수집 및 윤리적 고려 ····· 26
대상자 선정 ····· 26
자료추출 및 연구변수 ····· 28
자료분석방법 ····· 31
데이터 전처리 ····· 31
학습방법 ····· 33
예측 성능 평가 ····· 33

연구결과 ····· 37

논의 ····· 46

결론 및 제언 ····· 51

참고문헌 ····· 53

Abstract ····· 68

부록 ····· 70

List of Tables

Table 1. List of research variables ····· 30
Table 2. Evaluation index according to AUROC values ····· 34
Table 3. Confusion matrix ····· 35
Table 4. General characteristics of study subjects ····· 37
Table 5. Characteristics of in-hospital falls ····· 38
Table 6. Difference between fall group and control group according to fall risk ····· 40
Table 7. Predictive performance of machine learning algorithms ····· 43

List of Figures

Figure 1. Fall risk factor model of inpatients ····· 10
Figure 2. SVM algorithm ····· 17
Figure 3. RLR algorithm ····· 18
Figure 4. RF algorithm ····· 19
Figure 5. XGB algorithm ····· 20
Figure 6. Conceptual framework ····· 25
Figure 7. Patient inclusion flowchart ····· 27
Figure 8. Machine learning process flowchart ····· 36
Figure 9. Prediction performance of MFS ····· 42
Figure 10. Sensitivity and specificity of machine learning algorithms ····· 43
Figure 11. Fall risk factors ranked by feature importance ····· 45

서론

연구의 필요성

낙상은 의료기관에서 가장 많이 발생하는 환자안전사고 중 하나이다[1]. 의료기관평가인증원 환자안전보고학습시스템에 의하면 2020년 국내 의료기관에서 발생한 환자안전사고 중 낙상보고건수가 6,903건(49.6%)으로 낙상 발생이 가장 많다고 보고되었다[2].

입원환자의 낙상은 재원일수 증가, 추가적인 의료비용뿐만 아니라 의료인과 환자 간의 법적 소송의 원인이 되고 있다[3]. 그리고 예기치 못한 상황으로 인하여 환자 및 보호자에게 시간과 비용을 가중시키는 부정적인 영향을 끼치게 된다[4]. 낙상의 경우 환자에게 경미한 손상부터 골절, 뇌손상 및 출혈 등 심각한 신체적 손상을 초래할 뿐만 아니라 심지어는 사망에 이를 수도 있고[5], 불안, 두려움, 우울 등과 같은 정신적 손상까지 입힐 수 있다[6].

급성기 입원환자 중 특히 뇌혈관질환의 입원환자는 낙상 발생률이 매우 높다[7]. 뇌졸중 입원환자의 14-39%는 병원 입원 기간 중 낙상을 경험하고[8], 1회 이상의 낙상이 매우 흔하게 발생한다. 급성기 입원환자의 낙상위험요인을 보면 65세 이상의 고령, 입원 중 낙상 경험, 신체 기동성 장애, 어지럼증 혹은 현훈, 불안정한 걸음걸이, 전신 쇠약, 보행 보조기구 사용, 시력장애, 섬망, 자신의 상태에 대한 이해 부족, 신경계 질환, 중추신경계 약물 사용 등이 중요한 요인으로 작용하고 있다[9].

급성기 뇌졸중 입원환자는 급성기 입원환자의 낙상위험요인 외에도 여러 기능의 장애로 예측할 수 없는 자세가 발생할 경우 균형의 재빠른 확립이 불가능하기 때문에 상대적으로 더 많은 낙상을 경험하게 된다[10]. 또한 급성기 뇌졸중 입원환자의 낙상위험요인은 운동장애, 감각장애, 기능적 손상, 감소된 인

지, 신경학적 질병의 존재, 약물의 사용 등이 원인으로 발생한다고 하였다[8,11-14]. 이처럼 낙상은 중증 환자를 대상으로 한 의료기관의 경우 여러 가지 상호 복합적인 요인과 함께 특히 질병의 특성에 따른 낙상위험요인을 포함하여 예측하여야 한다[4].

국제의료기관 평가위원회(Joint Commission International: JCI)는 국제 환자 안전 목표 6가지 중 하나로 낙상 예방을 선정하여 전 세계 의료기관의 참여를 권장하고 있다[15]. 또한 급성기 의료 환경은 매우 도전적이고 복잡하기 때문에 궁극적으로 환자 안전을 보장하는 길은 낙상 예방 전략 중 하나인 낙상위험요인을 규명하는 것이라고 하였다[16,17]. 이와 같이 간호사는 환자의 특성에 맞게 낙상 위험도를 파악하여 사정하고 낙상을 미리 예측하는 것을 중요하게 고려하여야 한다.

현재 대부분 의료기관에서는 간호사가 모든 입원환자에게 낙상위험도 평가도구를 이용해 사정하고 그 결과에 따라 간호중재를 제공하고 있다. 그러나 낙상위험도 평가도구는 간호사의 판단에 따라 동일한 환자의 낙상위험도가 달라질 가능성이 있고[18], 낙상 고위험군보다 오히려 저위험군에서 낙상 발생률이 더 높게 나타났다는 연구 결과도 있으므로 국내 의료기관에서 사용하고 있는 낙상위험도 평가도구에 대한 재검토가 필요하다[4].

미국간호협회는 낙상위험도 평가도구의 정확도에서 의료기관별 환자군 특성에 따라 차이를 보이고 있으므로 어떤 도구를 정해서 추천하고 있지 않으며 각 의료기관의 환자 특성 및 요구를 반영한 위험 예측을 하도록 권하고 있다[19]. 급성기 입원환자들은 의학적 상태가 빠르게 변화하는데, 낙상위험도 평가도구에는 이러한 임상적 요인에 대한 고려가 부족하여[20] 최근 미국보건의료연구소(Agency for Healthcare Research and Quality: AHRQ)는 병원에서 낙상을 예방하기 위하여 기존의 낙상평가도구 외에도 약물, 동반질환, 혈액검사 결과, 환자의 교육 수준을 추가적으로 고려할 것을 권고하고 있다[21]. 또

한 각 의료기관의 환경이나 대상자의 특성에 따라 낙상 위험도는 서로 다르기 때문에 이를 고려하여야 한다[20].

선행 연구들을 살펴보면, 낙상의 위험요인이나 예측요인, 낙상사정도구의 검증 등 낙상의 위험을 미리 예측하고 이를 교정하기 위한 노력이 지금까지 지속되어져 왔으며, 이와 관련된 여러 연구들이 발표된 바 있다[22,23]. 최근에는 의료기관의 낙상 실태와 낙상 관련 특성 및 예측요인, 낙상에 대한 구조모형, 진료과별 낙상 등에 대한 연구들이 발표되었다. 여러 연구에서 볼 수 있듯이 임상 실무에서 사용 중인 낙상위험도 평가도구의 단점이나 한계를 보완하고 낙상 예측을 높이기 위한 방안으로 환자의 임상 상황에 따른 다양한 특성을 반영하는 낙상 예측의 필요성은 꾸준히 제기되고 있음을 확인할 수 있었다[9]. 낙상은 오랫동안 위험요인 사정 및 예방에 대한 노력을 기울여 왔지만 낙상 발생률은 여전히 높고 예방 중재 효과 또한 실무 기대 수준에 미치지 못하고 있다[4]. 이에 따른 입원환자의 질환별 환자 특성에 따른 낙상에 대한 연구 및 개별 환자마다 위험도를 평가하고 예측하는 연구는 부족한 실정이다.

낙상이 자주 발생하는 급성기 뇌졸중 입원환자는 일반적인 특성과 약물, 동반질환, 혈액검사 결과 등의 낙상 위험에 대한 파악과 기존의 낙상위험도 평가도구 그리고 추가적으로 뇌졸중의 상태를 평가하는 기능 상태 및 신경학적인 상태 검사 등의 다양한 위험요인을 고려하여 낙상위험을 분석하고 보다 정확한 낙상 예측을 수행할 필요가 있다.

대부분 의료기관들은 전자의무기록시스템을 활용하여 환자의 정보를 기록하고 있다. 기록된 환자 정보 자료는 의료기관 내부의 신뢰할 만한 데이터로서 기존에 수집된 다양한 임상데이터로부터 찾아낸 환자의 특성, 패턴 등 환자의 정보를 이용하여 자동화를 통한 서비스도 제공할 수 있다[24].

이러한 전자의무기록의 장점을 활용하여 다양한 낙상위험요인을 파악하고 기계학습에 기반한 낙상 예측 시스템을 제공한다면 간호사가 별도 검색을 통해

수동으로 데이터를 수집해야 하는 번거로움과 업무 부담을 경감시킬 수 있다. 또한 업무시간을 효율적으로 사용할 수 있을 뿐만 아니라 낙상에 대한 정확한 예측을 통한 간호를 제공할 수 있을 것이다.

최근 기계학습을 기반으로 하는 연구가 활발해지고 있다. 의료 분야 연구에서는 예측 모델 구현에 주로 활용되고 있으며, 나아가 질병 중증도의 분류, 의학적 의사결정, 그리고 새롭게 개발된 치료적 중재의 적용으로 그 영역을 확장해 가고 있다[25,26]. 기계학습에 기반한 모델은 다양한 변수들을 통하여 빠르게 예측할 수 있고, 특정 상황에서 환자의 예후나 예측이 가능하다. 아울러 기계학습에 기반한 알고리즘은 프로그램을 이용해 자동화가 가능하기 때문에 충분한 데이터와 적합한 알고리즘을 사용한다면 사람이 만든 모델보다 좋은 결과를 보여줄 수 있다[27].

기계학습 알고리즘은 한 가지만을 사용하는 것보다는 데이터셋(dataset)에 따라서 예측모델이 잘못 구성될 수 있으므로 랜덤 포레스트, 서포트 벡터 머신, 결정트리모델, 딥러닝 모델 등 다양한 기계학습 프레임워크를 사용하여 구성한 후에 선정할 필요가 있고[28], 상황에 따라 가장 적합한 알고리즘을 선택하는 것은 매우 중요하다.

따라서 가장 대표적이고 활용성이 높은 기계학습에 기반한 알고리즘 중 낙상에 대한 예측력이 높고 작동기전은 다른 알고리즘 4개를 선정하여[29-33] 기계학습을 기반으로 낙상위험도 평가도구의 한계점을 극복하고 급성기 뇌졸중 입원환자의 보다 높은 낙상 예측 알고리즘을 제안하고 낙상위험 중요 변수를 파악하고자 한다.

연구목적

본 연구는 급성기 뇌졸중 입원환자들에게 특화된 낙상위험을 예측하여 향후 급성기 뇌졸중 입원환자의 낙상 관리를 위해 실제적으로 임상에 활용하기 위한 기초자료를 제공함을 목적으로 한다. 구체적인 연구목적은 다음과 같다.

첫째, 기계학습 알고리즘을 적용하여 낙상위험 예측 성능 결과를 파악한다.
둘째, 기계학습 알고리즘을 적용하여 낙상위험 중요 변수를 파악한다.

용어의 정의

급성기 뇌졸중 입원환자

뇌졸중은 뇌혈관이 막히거나, 터져서 갑자기 운동기능을 상실하고, 감각이 변화하며, 인지기능의 장애와 언어기능의 장애, 균형감각의 소실, 의식 소실 같은 것을 특징으로 하는 신경계 질환이다[34]. 본 연구에서는 발병 후 신경과, 신경외과에 처음 입원한 뇌출혈과 뇌경색 환자를 의미한다.

낙상

낙상이란 의도하지 않은 자세의 변화로 완전히 균형을 잃고 손, 둔부, 머리 등과 같이 신체 부위가 바닥에 닿게 되는 현상이다[35]. 본 연구에서는 급성기 뇌졸중으로 입원한 환자가 낙상으로 인하여 낙상발생보고서로 보고된 사례를 의미한다.

낙상위험도

낙상위험도는 대상자의 갑작스러운 비의도적인 자세 변화 때문에 바닥에 주저앉거나 넘어지거나 눕게 되어서 본래 몸의 위치보다 낮아져 그로 인해 해로움이나 손실이 생길 우려가 있는 정도를 말한다[36]. 본 연구에서는 낙상 가능성이 있는 위험요인을 사전에 평가하는 낙상위험도 평가도구(Morse Fall Scale: MFS)를 의미한다[17].

낙상위험요인

낙상위험요인은 낙상의 발생 가능성을 증가시키는 요인을 말한다[37]. 본 연구에서는 환자안전 국제분류체계(International Classification for Patient Safety: ICPS)의 개념적 틀을 수정 보완한 낙상에 대한 근거기반 임상간호실무지침(Evidence-Based Clinical Nursing Practice Guideline)의 7개 위험요인군을 의미한다[38]. 낙상에 대한 근거기반 임상간호실무지침의 7개 위험요인군을 바탕으로 전자의무기록 포함 여부와 추가적인 문헌고찰 결과를 고려하여 추출한 자료이다.

기계학습 알고리즘

기계학습은 인공지능의 한 분야로, 인공지능이 인간의 지능을 기계로 구현하는 모든 형태를 말한다면, 기계학습이란 인공지능을 만들기 위해서 기존의 프로그램과는 달리 코드로 정의하지 않고 컴퓨터에 데이터를 주고 학습하게 함으로써 새로운 지식과 능력을 얻게 하는 것을 말한다[39]. 기계학습을 위한 수많은 종류의 알고리즘이 있으며 최근에도 새로운 알고리즘이 개발되고 있다.

기계학습 알고리즘은 문제의 종류, 데이터의 크기 등에 따라 적합한 알고리즘을 사용해야 원하는 결과를 얻을 수 있다[40]. 본 연구에서는 기계학습에 기반한 급성기 뇌졸중 입원환자의 낙상 예측을 알아보기 위한 서포트 벡터 머신(Support Vector Machines: SVM), 정규화 로지스틱 회귀분석(Regularized Logistic Regression: RLR), 랜덤 포레스트(Random Forest: RF), XG 부스팅(Extreme Gradient Boosting: XGB)의 4개 알고리즘을 의미한다.

문헌고찰

급성기 뇌졸중 입원환자의 낙상

병원이나 요양시설에 입원하고 있는 환자들은 흔하게 낙상을 경험하게 되고[41], 1년 이내에 낙상을 경험한 입원환자의 재 낙상률은 29.1%로 보고되고 있다[42]. 입원환자들이 경험하는 낙상은 복합적 요인들이 함께 상호작용하여 발생하고[43,44], 생리적 변화 및 약물, 질환 등 환자들이 가지고 있는 내적 요인과 다양한 환경적 위험을 포함하는 외적 요인이 낙상 발생 위험을 증가시킨다[45]. 뇌졸중은 뇌 혈류의 장애로 인해 갑작스럽게 뇌세포가 손상되어 신경학적 손상을 초래하는 질환으로 일단 발병을 하면 뇌 손상 부위, 범위 및 위치에 따라 편마비, 언어장애, 시각장애, 어지러움, 연하장애, 감각장애, 배뇨장애 등의 문제가 야기된다[46]. 뇌졸중으로 인한 편마비가 있는 경우에는 낙상의 빈도가 높고 비정상적인 보행과 근력 약화 및 기능적 제한으로 인한 이차적 손상이 생길 위험성이 높아진다[47]. 뇌졸중 환자들은 균형감각 문제로 인하여 낙상의 위험이 증가하는데 뇌졸중 이후 발생되는 편마비로 인한 자세의 비대칭과 신체의 불균형으로 기립과 보행에 장애가 생기며 일상생활을 수행하는데 어려움을 겪게 되므로 질병에 따른 낙상의 위험도 분석 및 예측은 매우 중요하다[48]. 또한 뇌졸중 입원환자의 낙상은 근력의 약화, 균형감각의 저하, 보행기능의 장애, 인지기능과 공간 감각의 저하 등 포괄적인 기능장애의 결과로 발생하기 때문에 다양한 낙상위험을 분석하고 예측할 필요가 있다[49].

낙상위험도

낙상위험도 평가도구인 MFS는 환자에게 낙상 위험요인의 존재 유무를 평가

하는 도구로 현재 많이 사용되고 있다[21]. MFS는 낙상 과거력, 이차적 진단, 보행 보조기구의 사용 여부, 정맥주사나 헤파린 캡, 보행, 보행장애에 대한 인지능력 등의 6개 항목으로 구성되어 있다[21]. 낙상 과거력이 있는 경우 25점, 없는 경우 0점, 이차적 진단이 있는 경우 15점, 이차적 진단이 없는 경우 0점으로 측정한다. 보행 보조기구의 사용 여부는 보행 보조기구 이외에 기구를 사용하는 경우 30점, 목발, 지팡이, 보행기를 사용하는 경우 15점, 사용하지 않는 경우나 휠체어 사용, 침상 안정, 부동(bed ridden)은 0점으로 측정한다. 정맥주사나 헤파린 캡이 있으면 20점, 없으면 0점을 부여하고, 보행장애는 균형을 잡기 어렵고, 사람이나 기구의 도움이 없이 걸을 수 없는 경우 20점, 보폭이 좁고 허약하게 걷는 경우 10점, 정상 보행이거나 절대 안정, 부동의 경우 0점으로 측정한다. 보행장애에 대한 인지능력은 장애가 있는 경우 15점, 잘 알고 있는 경우 0점으로 측정한다. 총 MFS의 점수는 최저 0점에서 최고 125점이 되며, 51점 이상인 경우에는 고위험군으로 분류한다[50]. 이에 국내에서 가장 많이 활용되고 있는 낙상위험도 평가도구인 MFS의 6개 항목이 낙상위험요인이므로 급성기 뇌졸중 입원환자의 낙상위험요인에도 포함하여 고찰해 보고자 한다. 그리고 MFS 단독 낙상 예측과 기계학습 알고리즘의 낙상 예측 결과를 파악하여 예측 성능 결과를 비교해보고자 한다[50].

낙상위험요인

세계보건기구(World Health Organization: WHO)에서 제시한 환자안전 국제분류체계(International Classification for Patient Safety: ICPS)의 개념적 틀에서는 환자안전사고를 줄이기 위해서 환자 특성과 사고 관련 특성이 작용할 수 있음을 포괄적으로 제시하였다[51]. 주요 영향요인 사이의 상호 연관성 분석을 통하여 환자안전사고 위험의 식별, 예방, 발견 및 사고 발생 후 개선 과정에

체계적으로 접근할 수 있으며, 이를 통해서 지속적인 의료의 질 향상을 도모할 수 있다[51]. ICPS의 개념적 틀은 의료기관에서 발생하는 위해 사건에 대한 공통 개념틀로 다른 부분의 안전 문제와 비교할 수 있고 공통적인 요소와 차별화 요소를 살펴볼 수 있는 장점을 갖고 있다[52,53]. 따라서 병원간호사회에서는 ICPS의 개념적 틀을 이용해 근거기반 임상간호실무지침의 낙상위험요인을 적용하여 입원환자의 낙상을 관리하도록 권고하고 있다[38](Figure 1). 7개의 위험요인은 환자의 특성, 정신 인지요인, 병태생리적 요인, 치료적 요인, 행동요인, 상황요인, 물리적 환경요인이다. 이러한 7개 위험요인군은 서로 상호작용하면서 환자 결과, 즉 결과지표로서 낙상 발생률과 손상 동반 낙상 발생률에 영향을 준다[38].

Patient Characteristics	나이, 성별, 수술/시술, 입원동기, 진단명
Mental Cognitive Factors	섬망, 치매, 지남력 장애, 의식상태, 불안, 안절부절, 불이행 등
Pathophysiologic/Disease-related Factors	질환요인, 영양불량, 탈수 등
Therapeutics	고위험 약물 사용, 부작용 확인 등
Behavioral Factors	낙상 과거력, 두려움, 약물 과거력, 수명장애 등
Situational Factors	보호자, 간호사, 간병인 등 돌봄제공자 상주 등
Physical Environmental Risks	심리적, 물리적, 공간적 낯설음, 보호장비, 기구 점검 상태 등

⇩

Patient Result

Figure 1. Fall risk factors model of inpatients

본 연구는 급성기 뇌졸중 입원환자에게 적용하기 위하여 7개 위험요인군으로 분류하여 살펴보았다.

첫째, 환자의 특성(patient characteristics)을 보면 수정이 불가능한 특성으로 나이, 성별, 수술/시술 또는 일차진단명을 포함한 입원동기, 이차진단명이 포함된다[38]. 급성기 뇌졸중 입원환자는 성별과 나이, 일차진단명에 포함되는 뇌졸중의 분류, 이차진단명의 환자의 특성과 그 외 추가적으로 입원 경로, 입원 방법, 사회 경제적인 요소의 파악은 필요하다.

둘째, 정신 인지요인(mental cognitive factors)에는 섬망, 치매, 지남력 장애, 의식상태, 불안, 안절부절, 불이행, 비협조적인 평가가 포함된다. 섬망이나 의식상태는 변동이 많은 특징이 있고 환자의 상태에 따라 변화가 많기 때문에 검증된 섬망 도구를 사용해야 한다. 그리고 동요하거나 방황하는 인지장애가 있는 대상자의 경우 상주 인원 또는 매 15분마다 확인하는 등 철저한 감독이 필요하다. 또한 동요를 유발시킬 수 있는 약물을 확인하는 것은 자신이나 타인에게 위협이 되기도 하고 필요한 치료를 방해 받을 수도 있으므로 검토가 필요하다[38]. 그러므로 정신 인지요인에서 의식상태의 파악은 필요하다.

셋째, 병태생리적 요인(pathophysiologic/disease-related factors)에는 감각기능 장애, 근육감소증, 현훈과 어지러움, 기립성 저혈압, 장애 및 절단, 근육허약, 느린 반사, 실신 경험 같은 증상, 실금, 영양불량을 포함한 균형과 보행 및 이동장애, 암, 혈우병, 뇌졸중, 파킨슨 질환, 다발성 경화증, 골관절염, 골다공증 등과 같은 질환 요인이 있다[38]. 또한 영양불량과 탈수도 근육 허약이나 기능장애와 인지장애, 신체적 활동의 감소 결과를 가져오고 이러한 부족 현상이 낙상과 관련이 있다. 그러므로 급성기 뇌졸중 입원환자의 영양상태를 반영하는 혈액학적 수치인 알부민과 헤모글로빈 수치를 고려하여야 한다.

그리고 뇌졸중 임상연구센터와 건강보험심사평가원에서 급성기 뇌졸중 평가에 사용되는 일상생활동작 수행 능력을 평가하는 일상생활동작검사(Modified Barthel Index: MBI)와 신경학적 중증도를 파악하는 검사(National Institutes of Health Stroke Scale: NIHSS), 그리고 신체 기능장애의 정도를 평가하는

검사(Modified Rankin Scale: mRS)의 척도를 고려하여야 한다[54].

급성기 뇌졸중 입원환자의 일상생활동작을 평가하는 MBI의 척도는 입원 혹은 집중적인 입원 재활치료를 시작하는 시점에 평가를 실시한다. 뇌졸중 환자의 낙상은 주로 하지의 근력저하로 발생하는 보행능력이나 균형감각이 저하되어 있으며 일상생활동작은 어느 정도 독립적으로 수행이 가능한 환자에서 발생한다고 하였다[8,55]. 그리고 뇌졸중 환자를 대상으로 낙상 유무와 MBI 상관관계 연구에서 통계적으로 유의한 상관관계가 있었다[56]. MBI는 일상생활동작 수행 능력을 평가하는 것으로 환자의 기능적인 독립 수준을 반영하는 평가이다. 일상생활활동을 10가지 세부 항목으로 나누고 그 중에서 신변처리동작 7개 항목과 가동 능력 3개 항목으로 구분하였고, 0점(전혀 수행할 수 없음)-15점(완전히 독립적으로 수행) 척도로 구성하였다. 개인위생, 목욕, 휠체어 이동은 0점(전혀 수행할 수 없음)-5점(완전히 독립적으로 수행) 척도로 구성하였고 용변, 식사, 계단 오르내리기, 착탈의, 대소변 조절은 0점(전혀 수행할 수 없음)-10점(완전히 독립적으로 수행)으로, 보행과 이동은 0점(전혀 수행할 수 없음)-15점(완전히 독립적으로 수행) 척도로 구성하였다. 다른 평가도구에 비해 검사항목이 간단하며 평가가 쉽고 정확하여 자조활동과 운동성에 대한 훈련에 널리 이용되고 있다[57]. 점수는 0점-24점은 완전 의존성, 25점-49점은 최대 의존성, 50점-74점은 부분 의존성, 75점-90점은 약간 의존성, 91점-99점은 최소 의존성, 100점은 완전 독립성을 나타낸다[58].

NIHSS는 미국국립보건원에서 개발한 방법으로서 뇌졸중의 심한 정도를 평가하는데 임상에서 널리 사용되는 척도이다[48]. 초기 뇌졸중 환자들에게 사용되는 신경학적 중증도를 평가하는 NIHSS 척도가 낙상을 결정하는 요인 중 하나라고 하였다[59]. NIHSS는 의식수준, 주시(gaze), 시야(visual field), 안면마비, 상지운동능력, 하지운동능력, 팔다리 운동실조(ataxia), 감각, 언어, 구음장애(dysarthria), 운동소거(extinction)와 주의력소실(inattention)과 같은 11개

검사항목으로 구성되어 있다. 각 항목당 정상인 경우는 0점이고, 중한 정도에 따라 1점에서 4점까지 점수를 부여하여 정량화한다. 임상 상태가 심할수록 점수가 더 높으며, 최대점수는 42점이다[48].

신체 기능장애의 정도를 평가하는 mRS의 척도는 낙상의 위험요인을 분석하는 도구로 많이 사용되고 있으므로 이 척도로 낙상위험도를 알아보고자 한다[60-63]. mRS는 1957년 Rankin에 의해 처음으로 소개되었고 1988년 Swieten 등에 의해 개발되었다[64]. mRS는 뇌졸중 환자의 일상 활동에서 장애 정도 혹은 의존도의 정도를 평가하는 데 흔히 이용되는 척도이다. mRS 점수는 0점-6점으로 정량화한다. 아무런 증상이 없을 때는 0점, 발병 전의 모든 업무와 일상 활동의 실행이 가능한 경우는 1점, 발병 전의 모든 일상 활동을 수행할 수는 없지만 도움이 없이 스스로 일상적 용무는 처리할 수 있는 경도의 장애는 2점, 약간의 도움이 필요하지만 다른 사람의 부축을 받지 않고 걸을 수 있는 중등도의 장애는 3점, 보조나 다른 사람의 도움이 없이는 보행이 불가능하고 대소변 처리와 위생관리를 스스로 수행할 수 없는 중등도의 심한 장애는 4점, 침상 의존상태이고 대소변 실금이 있으며 지속적인 간호와 주의가 필요한 중증 장애는 5점, 사망한 경우는 6점이다[64].

넷째, 치료적 요인(therapeutics)으로 대부분의 입원환자는 입원 직후 시작되는 각종 검사, 시술, 수술, 투약 등의 치료과정을 통하여 매일 상태가 변화한다[38]. 그리고 기저질환 치료와 관련하여 연관성이 높아 낙상 발생의 위험요인으로 작용한다. 이러한 상황은 대부분 환자의 처방이나 상태를 살펴보면 예측 가능한 경우가 많으므로 의료진의 세심한 주의가 필요하다. 치료적 요인 중 투약은 매우 중요한 항목이다. 의료진은 다중약물 또는 낙상위험과 관련된 고위험 약물 사용 여부를 확인하고, 약물 검토 및 부작용 등의 확인이 필요하다. 다약제 복용은 낙상위험요인으로 강조되고 있으므로 특히 주의해야 한다. 또한 건강 상태가 변화하는 경우에는 관련된 약물의 감소 및 용량을 줄이거나

중단하는 것이 낙상 예방에 도움이 된다고 제시하고 있다[65]. 그러므로 고혈압, 당뇨, 고지혈증, 부정맥, 심혈관질환, 골다공증, 척추질환, 뇌질환 등 동반질환의 여부를 고려하여야 한다. 그리고 항우울제, 항불안제, 항정신치료제, 항간질약, 이뇨제 등 다약제 복용 유무를 고려하여야 한다.

다섯째, 행동요인(behavioral factors)으로는 낙상 과거력, 낙상에 대한 두려움, 약물 과거력, 수면장애가 포함된다[38]. 입원환경에서의 행동요인은 과거력과 환경 변화에 따른 수면패턴이 포함된다. 입원이라는 낯선 환경에 예민한 경우에는 밤에 화장실 출입이 증가하게 되고 낮에는 수면을 취하거나 졸리는 현상이 발생하여 낙상 가능성을 증가시킬 수 있다. 또한 낙상 과거력은 고령자에게 강력한 지표이므로 낙상 두려움에 대한 조사를 권장하고 있다[66].

여섯째, 상황요인(situational factors)으로는 보호자, 간호사, 또는 간호조무사, 간병인 등 돌봄제공자의 침상 옆 상주는 낙상 예방에 영향을 주기 때문에 평가가 필요하다. 환자 옆에서 환자를 직접 돌보는 것은 환자의 낙상위험요인을 즉시 확인하고 필요한 도움을 제공할 수 있다[38]. 그러므로 보호자 및 돌봄제공자의 상주는 일반병동, 간호간병통합서비스병동, 중환자실로 구별하여 고려할 필요가 있다.

일곱째, 물리적 환경요인(physical environmental risks)은 심리적 낯설음과 함께 물리적, 공간적 낯설음이 있다. 입원은 환자들에게 매우 낯선 환경이므로 낙상과 밀접한 연관이 있어 평가가 필요하다. 바닥, 조명, 소음 상태, 병실 내 가구 배치, 휠체어 등과 같은 보호장비나 기구의 점검 상태는 낙상위험과 관련이 높다. 침대 높이가 높을수록 화장실 변기의 높이가 낮을수록 위험하다. 침상 난간, 화장실 내 손잡이와 바닥 상태, 부적절한 신발 등이 범주에 속한다[38]. 물리적 환경요인은 단일 의료기관이므로 동일한 것으로 간주한다. 이와 같이 모든 입원환자에 적용하는 포괄적인 낙상 위험요인과 함께 급성기 뇌졸중 입원환자의 특성을 나타내는 낙상위험요인도 함께 파악되어야 한다.

기계학습 알고리즘(Machine Learning Algorithm)

기계학습은 일반적으로 주어진 데이터를 분석하고 그 결과에서 규칙이나 새로운 지식을 자동으로 추출하도록 함으로써, 기계가 인간과 같이 학습하는 것과 같은 효과를 얻도록 한다. 기계학습은 데이터를 분석하고, 그로부터 어떤 값을 도출하는 것을 목표로 한다는 점에서 데이터마이닝과 비슷하다. 그러나 데이터마이닝이 데이터를 분석하기 위해 데이터의 구조, 특징 등을 발견하는 것에 초점을 맞춘다면, 기계학습은 데이터를 통해 새로운 현상을 예측하는 것을 목적으로 한다[40]. 기계학습 알고리즘은 실제로는 학습이 아닌 계산을 한다고 표현하는 것이 더 옳다고 할 수 있다[67]. 일반적으로 기계학습의 절차는 데이터 수집, 데이터 분석, 학습 및 평가, 검증 및 활용의 단계를 거친다. 데이터 수집 단계에서는 분석 데이터를 정리하고 수집 대상과 범위를 명확히 설정하여야 한다. 문제 해결을 위해서는 충분한 양의 데이터가 필요하기 때문에 직접 생성하거나, 데이터를 수집할 수 있는 별도의 환경 구축 또는 필요한 데이터를 보유하고 있는 곳이 있는지 확인해야 한다. 데이터 분석은 수집한 데이터를 분석하고 기계학습에 활용이 가능하도록 데이터를 정제하는 것이다. 탐색적 데이터 분석(exploratory data analysis)을 통해 시각적, 정량적 방법을 사용하여 데이터셋을 이해하고 요약한다. 이는 문제에 대한 적절한 모델을 개발하고, 결과를 올바르게 해석하는 데 도움을 준다. 데이터에 결측치, 이상치 등의 존재, 데이터의 불균형 등은 학습 과정에서 문제가 있으므로 이를 적절하게 처리해야 한다. 그리고 표준화, 정규화, 원-핫 인코딩(one-hot encoding) 등 데이터를 변환하여 기계학습이 잘 되도록 데이터셋을 구축한다. 학습 및 평가 단계에서 가장 중요한 것은 학습에 사용할 알고리즘을 선택하는 것이다. 그리고 많은 기계학습 알고리즘이 있으므로 해결할 문제와 데이터셋에 적합한 것을 선정해야 한다. 주로 숫자들로 이루어진 정형 데이터(structured data)로

이루어진 데이터셋에 대한 분류 및 회귀 문제는 SVM, 의사결정나무, RF, LightGBM 등을 사용한다. 마지막으로 검증 및 활용 단계는 개발된 기계학습 모델을 실제 현장에 적용하여 효과를 검증하고 활용하는 것이다. 그리고 활용하면서 발생하는 결과를 분석하여 기계학습 모델의 개선에 사용해야 한다[40].

최근 들어 기계학습을 활용하여 낙상을 예측하려는 여러 시도들이 있었다.

파킨슨병의 낙상에 대한 위험요인을 식별하기 위해 기계학습을 분석한 연구에서는 대부분의 낙상 예측은 로지스틱 회귀분석법을 활용하는데 선형적 관계만 분석하는 데에는 한계가 있어 다수의 입력변수와 비선형 관계에 대한 기계학습을 활용하여 낙상을 예측하였다. 그 결과 해당 연구에서 XGB 알고리즘에서 개발된 모델은 72%(p=.001)의 정확도를 보여주었고 재 낙상의 경우는 모델 정확도가 81%(p=.02)까지 올라갔다[30].

기계학습을 통하여 전자의무기록을 이용한 입원환자의 낙상 예측 알고리즘을 파악한 연구에서는 배깅(bagging), RF, 에이다부스팅(Adaptive boosting: Adaboost), 결정트리와 MFS의 예측력 비교 결과 배깅, RF, Adaboost가 MFS보다 훨씬 우수한 예측력을 보였다[31]. 코호트 연구에 기반하여 입원환자의 낙상 예측을 한 연구에서는 앙상블(ensemble) 기계학습을 활용하였으며 ROC 곡선 아래 영역의 넓이(Area Under the Receiver Operating characteristic Curve: AUROC)에서는 0.808의 정확도를 제시하였다[32]. 환자의 낙상 후 사망률을 예측하는 연구에서는 기존 선형 회귀분석 모델보다 기계학습 알고리즘이 낙상 후 더 정확하게 사망률을 예측할 것이라는 가설을 세우고 연구를 진행했으며 선형 회귀분석, 의사결정트리, 및 RF 알고리즘을 비교 분석한 결과 RF의 AUROC는 0.86으로 선형 회귀분석의 0.78보다 높았다[33]. 응급실을 방문한 환자들의 낙상위험도를 알아보는 연구에서는 낙상 예측 결과 RF가 0.78의 예측력을 보였다[22].

그러므로 본 연구에서는 낙상 예측에 가장 많이 활용되고 있는 작동기전이

다른 4개의 알고리즘을 적용하고자 한다.

첫째, 서포트 벡터 머신(Support Vector Machines: SVM)은 커널(kernel) 방법의 대표적인 알고리즘이다. 입력 데이터를 커널 기법을 사용하여 고차원으로 매핑함으로써 분류 문제를 간단하게 만들어 주는 방법이다[40]. 혼재된 개체들을 분류하는 방법 중 하나로 학습 데이터가 가상의 벡터 공간에 위치하고 있다고 가정하여 각 그룹을 분류하는 경계선을 찾고 이를 기반으로 패턴을 인식한다[68]. 이는 두 그룹을 분류하는 경계선의 거리를 최대로 만드는 과정을 통하여 더 높은 정확도 추구하게 된다. SVM은 선형 분류뿐만 아니라 커널화를 통한 비선형 분류에도 사용될 수 있다[69]. 서포트 벡터 머신은 아래의 알고리즘으로 본 연구에 적용하여 파악한다(Figure 2).

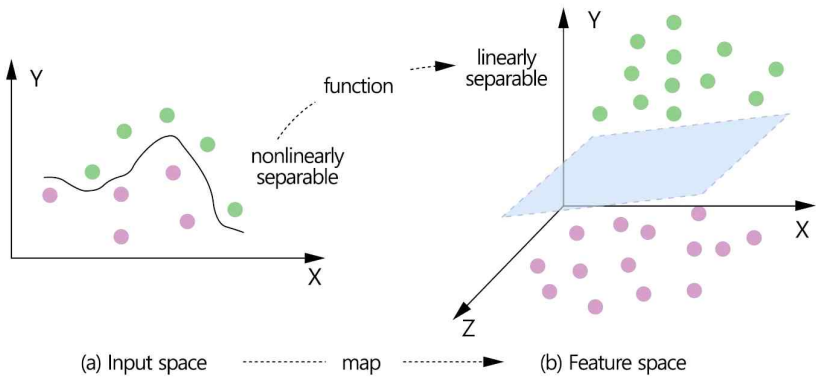

Figure 2. SVM algorithm

둘째, 정규화 로지스틱 회귀분석(Regularized Logistic Regression: RLR)이다. RLR은 의료분야 통계에서 흔히 쓰이는 선형 모델을 기반으로 하는 것이며, 특징이 많을수록 과적합(over-fitting)에 취약하게 된다. 고전적인 분류 알고리즘으로 빠르고 쉽게 적용할 수 있는 장점이 있으나, 문제는 과적합 가능성이

다. 이 과적합은 데이터가 많은 특징을 가지고 있는 경우 가설함수가 훈련 데이터에서는 매우 잘 맞지만 검증 데이터(validation data)에서는 일반화에 실패하는 것으로 정의되며, 이는 기계학습 알고리즘을 적용할 때 흔히 접할 수 있는 문제이다[70]. 이러한 과적합의 문제를 극복하기 위해 제시되는 것이 RLR이다. 이를 정규화를 통해 최소화하는 방식으로 진행하는데, 선형 방정식에서 높은 차수에 해당하는 변수에 대해 중요도를 낮추거나(L2 regularization), 변수 자체를 배제하는 방식(L1 regularization)으로 과적합을 극복하면서 예측력을 극대화할 수 있다[71,72]. 정규화 로지스틱 회귀분석은 아래의 알고리즘으로 본 연구에 적용하여 파악한다(Figure 3).

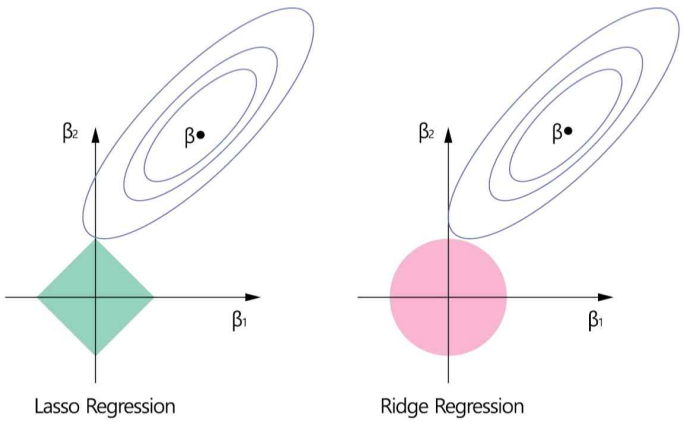

Figure 3. RLR algorithm

셋째, 랜덤 포레스트(Random Forest: RF)는 의사결정나무를 기반으로 한다. 다른 구조와 성능을 갖는 다수의 의사결정나무에서 각각 학습을 수행한 후 결합하는 배깅 방식을 사용한 앙상블 모델이다[40]. RF는 배깅이라는 방법을 활용하여 이러한 문제점을 극복하는 동시에 예측력을 향상시킨다. 배깅을 통해 여러 개의 의사결정나무를 형성하고, 각 트리가 분류한 결과에서 투표를

실시하여 가장 많이 득표한 결과를 최종 분류 결과로 선택하는 과정을 거친다[73]. 또한 데이터를 임의로 선택할 때 부트스트래핑(bootstrapping)을 허용하기 때문에 새로운 데이터셋을 계속해서 형성할 수 있는 장점이 있다[74]. RF는 의사결정나무에 기반한 학습 분류로 가지의 수가 많아질수록 과적합에 취약할 수밖에 없지만[67] 임의성을 가지고 있어 손실 데이터가 있거나 이상치가 포함되어 있어도 작동에 문제가 없을 만큼 유연성이 높다[40]. 그래서 의견을 통합하거나 여러 가지 결과를 합치는 앙상블 방식[75,76] 중에서 비교적 빠르고 성능이 우수하다. 랜덤 포레스트는 아래의 알고리즘으로 본 연구에 적용하여 파악한다(Figure 4).

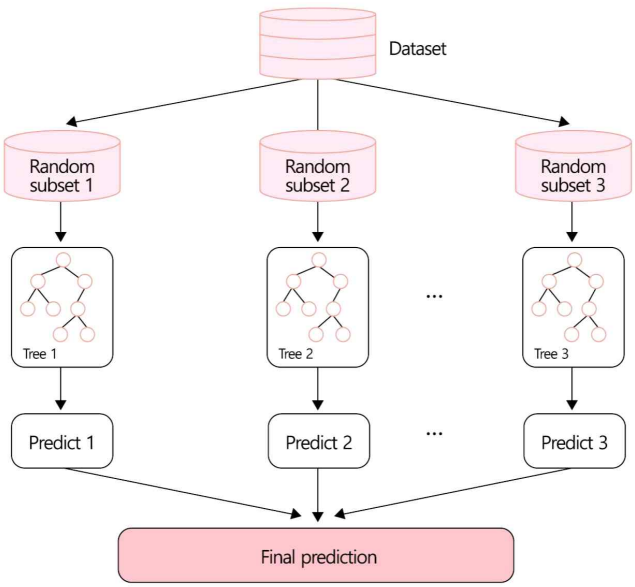

Figure 4. RF algorithm

넷째, XG 부스팅(Extreme Gradient Boosting: XGB)은 대표적인 앙상블 방식의 알고리즘이다[74]. 부스팅 기법은 여러 개의 약한 학습기(weak learner)

를 순차적으로 학습시키고 이를 결합하여 강한 학습기(strong learner)를 만드는 방법이다. 각 분류기에서 사용하는 데이터는 이전의 분류기의 결과를 바탕으로 가중치를 부여하고 학습을 진행함으로써 성능을 향상시킨다[40]. 이것은 순차적 학습을 통하여 가중치를 부여하는 방식으로 세부 모델간의 팀워크를 활용한다[76]. XGB는 가중치를 부여할 때 경사하강법을 사용하여 손실함수의 최적화를 찾는 방식으로 수행한다[77]. 예측값에 대한 차이값을 계산하고 이를 새로운 모델에 업데이트하여 합산해 가는 방식을 사용하고, 다양한 매개변수(hyperparameters)를 제공하여 최적화된 커스텀 옵션을 설정할 수 있을 뿐만 아니라 커스텀 모델은 자동 가지치기(auto pruning)등을 통해 과적합을 피하면서 예측력을 극대화할 수 있다[78]. XGB는 아래의 알고리즘으로 본 연구에 적용하여 파악한다(Figure 5).

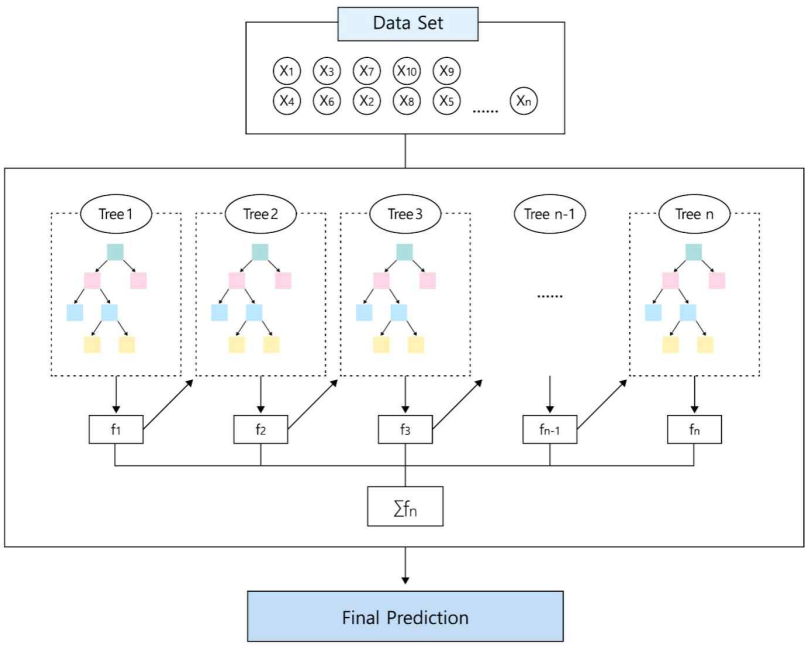

Figure 5. XGB algorithm

국외에서는 기계학습을 활용한 낙상 예측 관련 연구들이 진행되고 있다. 국내에서 시도되고 있는 기계학습 기반 낙상 예측 관련 연구는 대부분 공학적인 접근으로 시도되고 있어[79-81] 이에 낙상위험을 일반적이고 포괄적으로 제시하고 있는 낙상위험요인과 급성기 뇌졸중 입원환자의 특성을 고려한 다양한 요인을 파악하고 기계학습에 기반한 알고리즘을 통해 예측하여 보고자 한다.

국내에서 성인 입원환자에게 사용되고 있는 낙상위험도 평가도구에 대한 연구를 보면 MFS가 가장 효과적으로 낙상 위험을 예측하는 것으로 나타났다[82]. 그러나 다른 연구에서 낙상위험 예측은 대상과 의료 환경에 따라 예측 결과의 편차가 큰 것으로 나타났고[83], 낙상위험도 평가도구가 간호사의 임상적 판단보다 정확도가 떨어지는 것으로 나타났다[84]. 낙상위험도 평가도구의 경우에는 입력하는 사람에 따라 낙상 예측 결과가 달라질 수 있으며 사람이 데이터를 입력하기 때문에 인적오류(human error)도 간과할 수 없고, 시간 소요가 상당하다는 단점을 가지고 있다[84]. 간호사는 입원환자의 낙상에 대하여 책임과 부담감, 낙상 예방에 대한 어려움 및 예방전략의 부족, 낙상위험도 평가도구의 보완, 환경개선 및 인력지원 등을 호소하고 있다[85]. 이에 다양한 낙상위험요인을 파악하는 것은 매우 중요하므로 일반적인 낙상위험요인을 토대로 급성기 뇌졸중 입원환자의 질병 상태를 고려하여 파악할 필요가 있다.

이와 같이 급성기 뇌졸중 입원환자의 낙상위험을 파악하고 예측함으로써 낙상으로 인한 사고를 최소화하며 나아가 사전에 예방하는 것은 매우 중요하다[86]. 또한 질환별 특성에 맞는 정확한 낙상 예측을 통해 형식적이고 일반적인 교육이나 활동이 아닌 낙상위험을 가진 환자의 특성에 따른 중재 활동과 낙상과 관련된 환경을 정기적으로 사정하여 위험요인을 제거하고 관리하는 활동을 적극적으로 수행하여야 한다[87]. 간호사들이 이러한 질환별 특성을 고려한 낙상위험요인을 파악하여 예측하는 것은 많은 시간이 소요되고 업무의 부담이 가중되기 때문에 현실적으로 어렵다.

이에 본 연구에서는 간호사들이 질환별 특성을 고려하여 급성기 뇌졸중 입원 환자에 맞는 낙상위험도 평가도구인 MFS와[17] 근거기반 임상간호실무지침의 낙상위험요인[38] 등 다양한 요인을 포함하여 기계학습 알고리즘을 통해 보다 빠르고 정확한 낙상위험 예측을 고찰해 보고자 한다.

연구의 개념적 틀

본 연구의 개념적 틀

본 연구는 MFS의 낙상위험도와[17] 근거기반 임상간호실무지침의 낙상위험요인[38] 등을 통해 기계학습에 기반한 급성기 뇌졸중 입원환자의 낙상을 예측하고자 한다. 본 연구의 개념적 틀은 개념적 프레임워크에서는 크게 데이터셋, 기계학습 알고리즘, 예측 및 판단 등으로 단계를 구분된다(Figure 6).

데이터셋 단계에서는 급성기 뇌졸중 입원환자의 낙상위험은 현재 의료기관에서 가장 많이 사용하고 있는 낙상위험도 평가도구인 MFS와 낙상에 대한 근거기반 임상간호실무지침의 낙상위험요인에서 일반적이고 포괄적으로 제시하고 있는 7개 낙상위험요인군을 기반으로 전자의무기록을 통해 확인 가능하며 문헌고찰을 통해 중요 요소로 확인된 자료를 입력데이터로 사용하였다.

MFS의 낙상위험도는 낙상 과거력, 이차적 진단, 보행 보조기구의 사용 여부, 정맥주사나 헤파린 캡, 보행, 보행장애에 대한 인지능력으로 6개 항목의 총점이다.

낙상에 대한 근거기반 임상간호실무지침의 7개 낙상위험요인은 환자의 특성, 정신 인지요인, 병태생리적 요인, 치료적 요인, 행동요인, 물리적 환경요인, 상황요인이다.

환자의 특성은 성별과 나이, 일차진단명에 포함되는 뇌졸중의 분류, 이차진단명과 입원 경로, 입원 방법, 사회 경제적인 요소를 파악하였다. 정신 인지요인으로는 객관적인 섬망도구를 사용한 평가가 없어 포함하지 않았고 의식상태로 파악하였다. 병태생리적인 요인으로는 영양 상태를 반영하는 알부민과 헤모글로빈 수치와 뇌졸중의 질병 상태를 나타내는 척도인 MBI, NIHSS, mRS의 총점을 포함하였다. 치료적 요인으로 고혈압, 당뇨, 고지혈증, 부정맥, 심혈관질

환, 골다공증, 척추질환, 뇌질환 등 동반질환의 여부와 항우울제, 항불안제, 항정신치료제, 항간질약, 이뇨제 복용 등 약물복용 여부를 확인하였다. 행동요인 중에서는 낙상에 대한 두려움이나 수면장애는 중요한 지표이기는 하나 전자의무기록자료로는 확인할 수 없어 포함하지 않았고 낙상과거력은 MFS의 항목에 포함하여 평가하는 것으로 갈음하였다. 물리적 환경요인 중 바닥, 조명, 소음 상태, 병실 내 가구배치, 화장실 내 손잡이와 바닥 상태, 부적절한 신발 등은 전자의무기록자료로 확인할 수 없어 포함하지 않았으나 단일 의료기관 연구이기 때문에 동일한 환경의 조건으로 보았고 보행 및 보행보조기구의 사용은 MFS의 항목에 포함하여 평가하는 것으로 갈음하였다. 상황요인은 일반병동, 간호간병통합서비스병동, 중환자실로 구분하여 파악하였다.

기계학습 알고리즘 단계에서는 MFS와 ICPS의 개념적 틀을 이용한 낙상위험요인을 입력 데이터에 넣고 작동기전이 다른 4개의 알고리즘 SVM, RLR, RF, XGB를 사용하여 데이터 전처리를 통해 학습시켰다(Figure 2,3,4,5).

예측 및 판단 단계에서는 4개의 기계학습 알고리즘에 대한 적절한 예측 성능 평가 방법으로 AUROC를 주 결과로 해석하였고 민감도(sensitivity), 특이도(specificity), 정확도(accuracy), F1 스코어(F1 score), 양성예측도(Positive Predictive Value: PPV) 및 음성예측도(Negative Predictive Value: NPV)를 평가하여 최적의 낙상 예측 알고리즘을 제안하였다.

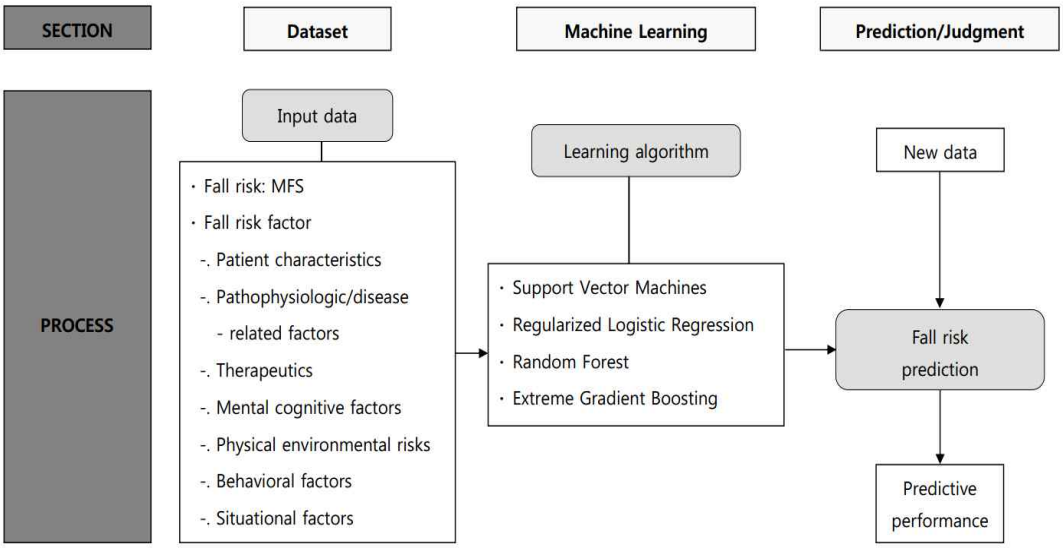

Figure 6. Conceptual framework

연구방법

연구설계

본 연구는 단일 의료기관의 전자의무기록 자료를 활용하여 기계학습에 기반한 낙상위험 예측 성능을 알아보고 낙상위험 중요 변수를 파악하는 후향적 사례-대조군 연구(retrospective case-control design)이다.

자료수집 및 윤리적 고려

자료수집은 연구자가 소속된 기관의 생명윤리위원회의 승인(승인번호: PSSH0475-202108-HR-016-04)을 받은 후 수행되었고 후향적 연구로서 자발적 연구 참여동의서는 면제되었다. 연구자가 소속된 기관의 의료질관리실 책임자의 허락을 받고 전자의무기록열람에 대한 승인을 받은 후 전자의무기록을 열람하였다. 2016년 1월부터 2022년 6월까지 급성기 뇌졸중을 주진단으로 종합병원이면서 뇌혈관 전문병원인 단일 의료기관에 입원한 환자의 특성 및 낙상위험도, 낙상위험요인 등을 사례조사양식에 작성하였다. 자료수집기간은 2022년 7월 1일부터 2022년 7월 15일까지 환자안전전담자 3인이 실시하였다.

대상자 선정

2016년 1월부터 2022년 6월까지 급성기 뇌졸중을 주진단으로 입원한 환자 8,462명을 대상으로 하였고 해당 기간 중 총 156건의 낙상 발생 건수를 포함하였다.

급성기 뇌졸중 주진단은 국제질병분류 ICD-10(International Classification of Diseases version 10)기준으로 I60 - I63으로 정의하였다. 낙상은 발생률이 매우 낮은 종속변수이기 때문에 대조군 선정에서는 대상 기간 동안 총 낙상 건수의 6배수에 해당하는 입원환자를 대조군 연구(nested case-control study setting)로 사용하여 탈락률을 고려한 936명을 무작위로 임의추출하였다. 각각의 낙상 사례들은 6배수의 대조군과 무작위로 매칭하였고 매칭은 같은 분기 내 그리고 같은 병동에 입원한 경우에 대한 두 가지 조건으로 수행하였다. 본 연구에서는 결측값이 있는 경우와 뇌졸중 진단이 불명확한 경우에는 대상에서 제외하였다. 무작위로 추출한 입원환자 936명 중에서 결측값을 가지고 있는 2명은 제외되었고 최종 934명이 최종 분석에 사용되었다(Figure 7).

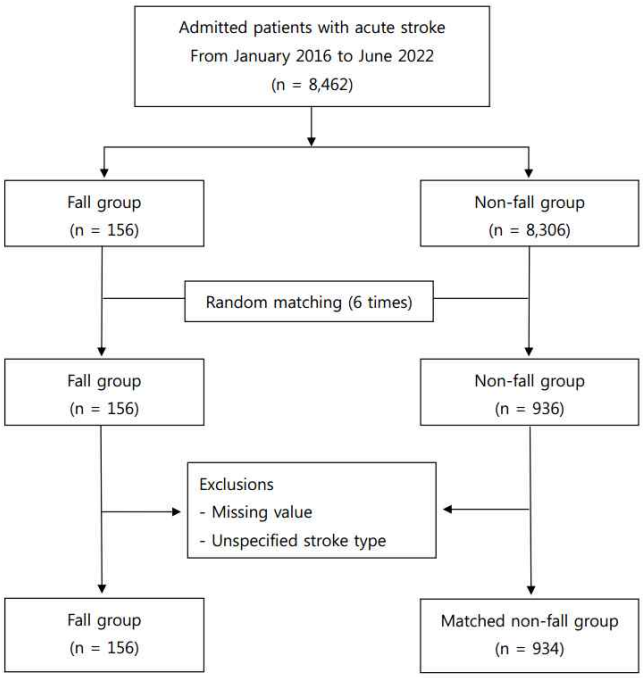

Figure 7. Patient inclusion flowchart

자료추출 및 연구변수

급성기 뇌졸중 입원환자의 낙상위험도 및 낙상위험요인은 전자의무기록 자료를 통하여 조사하였고 낙상발생보고서는 서면 자료로 조사하였다. 낙상의 예측을 위해서 전자의무기록에 기록된 입원 시 평가 가능한 지표들을 주요 변수로 사용하였고 최대한 많은 변수를 사용하기 위해서 통계적 유의성과 상관없이 잠재적 낙상 변수로 수집하였다.

전자의무기록자료는 간호초기평가기록지, 간호기록지, 투약 처방데이터, 검사결과데이터, 진단명 입력데이터, 퇴원요약지, 낙상사정기록지, NIHSS기록지, mRS기록지, MBI기록지로 확인하였다. 낙상 발생에 대한 특성은 낙상발생보고서를 통해서 확인하였다.

낙상위험도인 MFS는 세부 항목인 낙상 과거력, 이차적 진단, 보행 보조기구의 사용 여부, 정맥주사나 헤파린 캡, 보행, 보행장애에 대한 인지능력을 사정한 6개 항목으로 평가된 점수를 합한 총점을 기준으로 해당 병동 간호사가 입원 당시 낙상을 사정하여 평가한 낙상사정기록지를 통하여 확인하였다.

낙상환자 중 낙상 발생의 특성은 낙상이 발생한 부서에서 서면으로 제출한 낙상발생보고서로 확인하였다. 낙상발생보고서의 내용을 바탕으로 낙상 장소, 신체 손상 정도, 낙상 발생 시간, 낙상 발생 요일, 낙상 발생 병동 등도 확인하였다.

낙상위험요인은 각 대상자의 입원 기간 중 검사결과 데이터에서 낙상군은 낙상 발생 전 최근의 결과를 반영하고 대조군은 입원 당시 검사 결과를 반영하였다.

급성기 뇌졸중 입원환자의 특성에 대한 요인에 대한 변수는 나이, 성별, BMI, 입원 시 경로, 병동 종류, 입원 방법으로 하였고 입원 당시 간호초기평가기록지를 통해 확인하였고 뇌졸중의 종류, 의료보장 형태와 거주 지역은 퇴

원요약지를 통해서 확인하였다.

병태생리적인 요인에 대한 변수는 헤모글로빈, 알부민, MBI, NIHSS, mRS로 하였다. 영양 상태를 반영하는 생리학적 지표로 헤모글로빈, 알부민 수치를 확인하였고 뇌졸중의 질병 상태를 나타내는 척도인 MBI, NIHSS, mRS의 총점을 확인하여 평가하였다. 혈액검사 결과는 검사결과 데이터에서 추출하였고 헤모글로빈의 정상범위는 10.8-14.9 g/dL로, 알부민은 3.5-5.3 g/dL로 정의하였고 정상범위의 수치 외의 결과는 비정상 결과로 반영하였다. 뇌졸중의 질병 상태를 나타내는 척도 MBI, NIHSS, mRS는 의사가 직접 평가한 총점을 확인하였다. 평가 시점은 입원 당시 NIHSS기록지, mRS기록지의 총점을 통해 확인하였고, MBI기록지는 입원 후 재활의학과에서 가장 최근에 평가한 총점을 통해 확인하였다.

치료적 요인에 대한 변수는 동반질환 여부와 다약제 복용 유무에 대하여 확인하였다. 고혈압, 당뇨, 고지혈증, 부정맥, 심혈관질환, 골다공증, 척추질환, 뇌질환 등 동반질환의 여부를 확인하였고 항우울제, 항불안제, 항정신치료제, 항간질약, 이뇨제 복용 여부를 확인하였다. 환자의 동반질환은 입원 당시 진단명 입력 데이터를 통하여 고혈압(I10-I14), 당뇨(E10-E14), 고지혈증(E68), 부정맥(I46-I49), 심혈관질환(I20-I24), 골다공증(M80-M82), 퇴행성 척추질환(M43-M44), 신경퇴행성 뇌질환(파킨슨: G20-22, 치매: F00-F02, G30, G31, 다발성 신경계 위축: G23, 다발성 경화증: G34)등을 확인하였다. 투약은 처방 데이터를 통해 표준약물 코드명과 WHO에서 개발한 국제의약품(Anatomical Therapeutic Chemical: ATC) 분류코드로 확인하였고 낙상군은 낙상 발생일에 투여된 약물을 포함하고 대조군은 입원 당시 투여된 약물을 포함하였다.

정신 인지요인에 대한 변수는 의식상태를 확인하였고 간호기록지를 통해 확인하였다.

상황요인에 대한 변수는 보호자 및 돌봄제공자의 상주에 대해 확인하였고 간

호초기평가기록지를 통해 일반병동, 간호간병통합서비스 병동, 중환자실로 구별하여 확인하였다.

낙상 변수의 자료를 파악하기 위해서 전자의무기록의 열람 신청과 허락을 득하여 의무기록 자료를 검색하였고 낙상발생보고서는 해당 부서에 의뢰하여 허락을 거치고 자료를 확인하였다. 전체 낙상 변수를 체크리스트에 모두 표시하도록 하였고 수집 불가능한 경우는 체크리스트에 표시하지 않았다. 추가로 수집 가능한 자료는 기타 항목에 개방형으로 기입할 수 있도록 하였다. 낙상 변수를 조사한 자료를 종합하여 추출할 항목 및 코드를 지정하였다(Table 1).

Table 1. List of research variables

Fall risk category		Research variables	Source
Fall characteristics		Place, Injury, Time, Day	Fall occurrence report
Fall risk		MFS	Fall assessment record paper
Fall risk factor	Patient characteristics	Age, BMI, Sex, Residential areas, Ward types	First-time nursing record
		Stroke types, Insurance types, Residential areas	Discharge Summary record
	Pathophysiologic /disease-related factors	Hemoglobin, Albumin, MBI, NIHSS, mRS	Blood test result data MBI record NIHSS record mRS record
	Therapeutics	Comorbidities	Diagnostic name input data
		Availability of multi drugs	Drug prescription data
	Mental cognitive factors	Mental state	Nursing record
	Situational factors	Guardians and Residential care provider	First-time nursing record

자료수집의 편차를 줄이기 위하여 전자의무기록 자료 중 해당 변수가 포함된 각각의 항목을 전자의무기록 자료마다 각각 표시하여 정확한 데이터를 기록할 수 있도록 기준을 수립하였다. 또한 10년 이상 임상에서 근무한 환자안전전담자인 간호사 3인이 자료 입력 데이터에 대한 기준을 확인하고 구조화된 체크리스트를 구성하여 자료를 수집하였다.

자료분석방법

모든 통계적 분석 및 기계학습 과정을 위해서 R 소프트웨어 버전 4.2.1(R software version 4.2.1: R Core Team, R Foundation for Statistical Computing, Vienna, Austria)을 사용하였다.

연구대상자의 일반적인 특성과 낙상위험에 따른 낙상군과 대조군의 발생 차이 분석에서 연속형 변수는 평균 ±표준편차로 표시하고 범주형 변수는 빈도(백분율)로 표시하였다. 연속형 변수는 평균 ±표준편차로 표시하고 범주형 변수는 빈도(백분율)로 표시하였다(Table 4,6).

낙상 발생의 특성에 대한 빈도 분석은 백분율로 수행하였다(Table 5).

낙상군과 대조군의 차이를 비교하기 위하여 연속형 변수에서는 독립표본 t 검증(independent t-test)을 수행하였고, 범주형 변수에서는 카이제곱(chi square test)을 수행하였다.

통계적 유의수준은 $p<.05$로 기준을 설정하고 검정하였다(Table 6).

데이터 전처리

기계학습 예측을 수행하기 전에 데이터 전처리를 수행하였다.

우선 빈도가 낮은 변수 및 다중공선성을 보이는 변수들을 확인하고 제거하였

다. 이후 연속형 변수에 대해서 정규화 방법은 기초통계량이므로 일반적으로 사용되는 단순한 센터링(centering) 및 스케일링(scaling)을 수행하였다. 또한 범주형 변수에 대해서는 원-핫 인코딩을 수행하여 숫자형 변수로 변환하여 사용하였다.

데이터 정규화를 통하여 기계학습 과정에서 변수별 영향력의 차이를 줄이고, 학습 속도를 개선하며, 지역 최적화(local optimum)의 가능성을 줄일 수 있도록 하였다[88]. 결측치가 있는 데이터는 자동으로 프로그램에서 제거하였다.

기저질환 중 골다공증, 심혈관 질환, 및 퇴행성 척추 질환은 분산이 0에 수렴하는 변수들로 제외되었다. 모든 연속형 변수 간에 상관계수 0.75이상의 다중공선성은 확인되지 않았다.

데이터셋의 분리 비율은 일반적으로 8:2 또는 7:3을 사용한다. 데이터셋의 크기에 따라 좌우될 수 있으며 데이터가 충분하다면 검증데이터가 클 필요는 없다[40]. 본 연구에서는 전체 데이터는 7:3의 비율로 훈련데이터와 검증데이터로 무작위 배분하였다.

샘플링 방법은 먼저 소수 클래스에서 각각의 샘플들의 KNN(K-Nearest Neighbors)을 찾는다. 그리고 그 이웃들 사이에 선을 그어 무작위 점을 생성한다. 이렇게 생성하면 완전히 동일하진 않지만 샘플들 사이의 특성을 반영한 데이터가 생성되기 때문에 과적합에 강한 데이터가 생성된다[89].

본 연구에서는 과적합을 해결하기 위해서 기계학습 분야에서 가장 많이 사용하는 방법 중 하나인 스모트(Synthetic Minority Oversampling Technique: SMOTE)방법을 사용하여 종속변수의 밸런싱(balancing)을 수행하였다.

스모트를 적용한 훈련데이터의 낙상군 대 대조군 비율은 560:650이었다.

전처리가 완료된 데이터에서 훈련데이터는 낙상군 대 대조군 비율이 112:650이었으며, 검증데이터는 44:284를 포함하였다(Figure 8).

학습방법

기계학습 프로세스를 위하여 서로 다른 작동기전을 가진 SVM, RLR, RF, XGB 등으로 총 4개의 기계학습 알고리즘을 사용하여 학습시켰다.

기계학습 알고리즘의 성능에 대한 검증을 위해 k-교차검증(k-fold cross validation)을 수행하였다. 교차검증에서 사용된 반복 회수(k)는 10으로 설정하여, 훈련데이터와 검증데이터를 반복 변경하여 모델을 학습하고 평가된 결과의 평균 정확도를 초기 도출된 정확도와 비교하여 과적합의 여부를 확인하는 방법이다[90]. k-교차검증은 모든 데이터를 학습과 평가에 사용함으로써 데이터 양이 적을 경우에 정확도를 향상시킬 수 있으며, 데이터를 한번 나눌 때보다 더 일반화된 결과를 얻을 수 있다[91]. 본 연구에서는 내부 검증을 위하여 훈련데이터에서 10-fold 교차검증을 50번 반복하여 진행하였다.

기계학습 알고리즘의 최적화 작업은 다양한 매개변수(hyperparameter)를 갖고 있기 때문에 각각의 알고리즘에서 주어진 매개변수를 다수 반복하는 시뮬레이션을 통하여 작업을 하는 방법이다[90]. 본 연구에서는 랜덤 서치(random search) 및 격자 거치(grid search)를 혼용하여 사용함으로써 최적화를 진행하였다(Figure 8).

예측 성능 평가

일반적으로 기계학습 알고리즘의 구축된 성능을 판단하기 위해서 다음과 같은 지표를 사용한다. AUROC, 민감도, 특이도, 정확도, F1 스코어, 양성예측도 및 음성예측도로 평가한다. AUROC는 ROC곡선에서 산정된 그래프의 면적을 나타낸 지표이며, 이진 분류의 경우 분류 판정을 내리는 임계선의 민감도를 나타내는 지표이다. ROC 곡선은 민감도와 1-특이도의 그래프이며, 민감도는

재현율 값과 동일하다. 특이도의 경우 아래 나타낸 식을 활용하여 결정하게 된다. 의료데이터에서 많이 사용되는 성능 척도이고 검사 방법의 유용성 또는 확진을 내릴 수 없는 상황에서 사용되며 검사법의 기준치를 결정하려 할 때 많이 사용된다. 정확도는 결과값이 1.0일 경우가 가장 완벽한 검사방법으로 민감도와 특이도가 100%인 경우를 뜻한다(Table 2). 반대로 0.5일 경우에서는 특이도가 1일 때 민감도는 0, 특이도가 0일 때 민감도는 1이 되는 상충 관계(trade off)로 성능이 전혀 없다는 것을 뜻한다[92].

$$Specificity = \frac{TN}{TN + FP}$$

아래의 AUROC 값에 따른 모델의 평가 지표를 나타낸 표이다[93].

Table 2. Evaluation index according to AUROC values

AUROC	Result
0.9<AUROC≤1.0	Excellent
0.8<AUROC≤0.9	Good
0.7<AUROC≤0.8	Fair
0.6<AUROC≤0.7	Poor
AUROC≤0.6	Fail

정확도는 문제의 해결을 위하여 전체 데이터를 올바르게 구분한 정도를 나타내는 지표이고[94], 정확도를 평가하기 위해서 오차행렬(Confusion matrix)을 이용하였다[89,90](Table 3). F1 스코어는 정밀도와 재현율을 활용하여 데이터의 편중을 방지하고자 조합된 지표이다[95]. 재현율은 양성데이터 중에서 정확하게 양성을 구분한 정도를 나타내는 지표이며 사실-긍정율(True-Positive Rate; TPR)이라고도 불린다. 정밀도는 모델이 참(true)으로 분류한 데이터 중

에서 실제 참(true)의 비율로 양성예측도라고도 한다. 음성예측도는 음성데이터 중 정확하게 음성을 구분하는 비율이다[40].

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$F1\,Score = 2 \times \frac{\mathrm{Pr}ecision \times Recall}{\mathrm{Pr}ecision + Recall}$$

Table 3. Confusion matrix

Confusion matrix		Prediction	
		Negative	Positive
Reference	Negative	True Negative (TN)	False Positive (FP)
	Positive	False Negative (FN)	True Positive (TP)

기계학습 알고리즘의 성능 평가는 학습된 알고리즘이 얼마나 정확하게 예측했는지를 보여주는 것으로 매우 중요하다. 예측 알고리즘이 잘 작동하는지를 나타내기 위해서는 적절한 성능 평가 방법을 선택하여야 한다. 특히 불균형 데이터의 경우 적절한 방법으로 평가해야 원하는 성능을 확인할 수 있다[40].

본 연구에서는 MFS의 예측력을 확인하기 위하여 일변량 이항 로지스틱 회귀분석(univariable binary logistic regression model)을 적용하여 AUROC값으로 평가하였다. 기계학습 알고리즘의 예측 성능 평가는 AUROC를 주 결과로 해석 및 평가를 수행하였으며 민감도, 특이도, 정확도, F1 스코어, 양성예측도 및 음성예측도로 평가하였다(Figure 8). 기계학습 알고리즘의 낙상위험 주요 변수는 프로그램에서 계산하는 카렛 패키지(caret package)를 이용하여 자동으로 수행하였다.

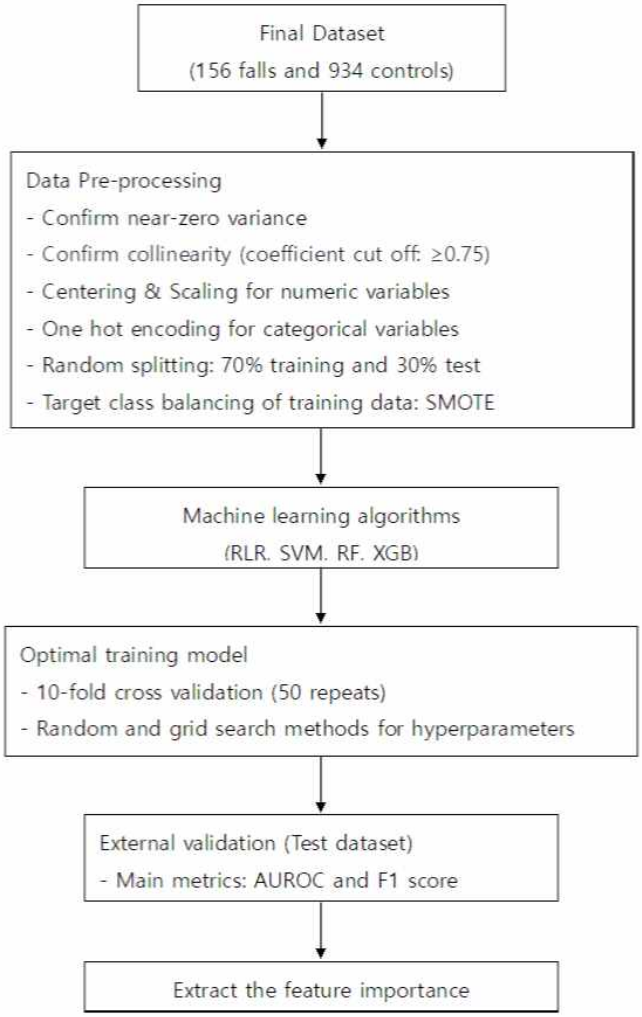

Figure 8. Machine learning process flowchart

연구 결과

연구대상자의 일반적인 특성

연구대상자의 평균 나이는 65.7±12.5로 나타났고, BMI는 평균 24.6±18.2로 나타났다. 성별은 남성이 56.0%로 여성보다 약간 높았다. 병동의 종류는 일반병동이 47.1%로 가장 높았고 의료보장형태는 건강보험이 91.0%로 가장 높았다.

Table 4. General characteristics of study subjects (*N*=8,462)

Variables		n(%) or M±SD
Age, years old		65.7±12.5
Body mass index, kg/m^2		24.6±18.2
Sex, n(%)		
	Male	4717(56.0)
	Female	3745(44.0)
Ward Type, n(%)		
	General	3989(47.1)
	INCS	3951(46.7)
	ICU/SU	522(6.2)
Insurance type, n(%)		
	NHI-covered	7697(91.0)
	Medical-aid	765(9.0)
Residential area, n(%)		
	Urban	4048(47.8)
	Rural	4414(52.2)
Stroke type, n(%)		
	SAH	832(9.9)
	ICH	1200(14.2)
	Ischemic	6430(75.9)
Admission route, n(%)		
	ER	4773(56.3)
	OPD	3869(45.7)

입원 경로는 응급실이 56.3%로 외래보다 약간 높았고 거주지역도 읍면지역이 52.2%로 조금 높게 나타났다. 뇌졸중의 분류는 뇌경색이 75.9%로 높았다(Table 4).

낙상 발생의 특성

낙상이 가장 많이 일어난 장소는 일반 병동 및 병실 안이 73.1%로 가장 높았고, 그 다음으로는 응급실, 중환자실, 뇌졸중 단위와 같은 특수환경에서 많이 발생하는 것으로 확인되었다. 실제로 낙상 후 수상이 없는 경우가 75%로 가장 많았고 혈종이 2.6%, 골절이 4.5%, 두부외상이 0.6%로 보고되었다. 한편 낙상은 비정규시간이 60.9%로 더 많이 발생하였고 주중보다는 주말에 발생한 건이 30.8%로 다소 그 비율이 높은 것으로 확인할 수 있었다(Table 5).

Table 5. Characteristics of in-hospital falls (*N*=156)

Variables	n(%)
Place	
Ward	114(73.1)
On the move	8(5.1)
ER/ICU/SU	21(13.5)
Other	13(8.3)
Injury	
None	117(75.0)
Abrasion/Laceration	27(17.3)
Hematoma	4(2.6)
Fracture	7(4.5)
Head trauma	1(0.6)
Time	
Working time (8:00 to 19:00)	61(39.1)
Other	95(60.9)
Day	
Weekday (Monday to Friday)	108(69.2)
Weekend	48(30.8)

낙상위험에 따른 낙상군과 대조군의 차이

일반적인 특성에 따른 낙상군과 대조군 간의 비교 분석 결과는 다음과 같다.

낙상위험도를 측정하는 MFS의 총점은 낙상군이 54.3±18.3점으로 대조군의 37.7±14.7점에 비해 유의하게 높았다.

낙상군의 평균 나이는 68.3±12.2세로 대조군의 65.3±12.9세와 비교하여 유의한 차이를 보이지 않았다. 반면 낙상군에서 남성의 비율이 51.3%로 대조군의 60.0%에 비하여 유의하게 낮았으며(p=.035), 몸무게는 23.2±3.1로 낙상군에서 대조군의 23.8±3.1에 비해서 유의하게 더 낮은 소견을 보였다(p=.041) 낙상군에서 헤모글로빈 수치가 유의하게 낮았으나(p=.045), 알부민 수치는 유의한 차이를 보이지 않았다. 비낙상군에서 간호간병통합서비스병동 입원비율이 50%로 낙상군에 비해 유의하게 높은 소견을 보였으며(p<.001), 낙상군에서는 응급실을 통한 입원 비율(p=.002) 및 침대차를 이용한 입원 비율이 유의하게 높은 결과를 보였다(p<.001).

뇌졸중 관련 변수들 중에서 낙상군에서 뇌출혈의 비율이 유의하게 높았다(p<.001). 또한 낙상군의 NIHSS 점수는 5.3±4.1으로 대조군의 4.0±6.2에 비해 유의하게 높은 소견(p<.001)을 보였다. 그 외에서 기능적 수준 지표인 mRS 점수에서도 낙상군에서 더 높은 소견(p<.001)을 보였고 MBI 점수는 더 낮은 소견(p<.001)을 보였다.

동반질환 중 낙상군에서 부정맥(p<.001), 퇴행성 척추 질환(p<.001), 및 신경퇴행성 질환(p<.001)의 비율이 유의하게 높은 반면에 고지혈증의 경우 대조군에서 유의하게 높은 소견을 보였다(p=.047). 낙상 관련 투약에서는 단일 및 다약제 투약 비율이 낙상군에서 유의하게 높았다(p<.001)(Table 6).

Table 6. Difference between fall group and control group according to fall risk (*N*=1090)

Variables	Total (n=1090)	Non-Fall (n=934)	Fall (n=156)	χ^2 or t	*p*
MFS	40.1±16.3	37.7±14.7	54.3±18.3	12.547	<.001
Age, years old	66.3±12.8	65.3±12.9	68.3±12.2	1.857	.063
Body mass index, kg/m^2	23.0±3.1	23.8±3.1	23.2±3.1	-2.046	.041
Male, n(%)	646(59.3)	566(60.0)	80(51.3)	4.785	.035
Hemoglobin, g/dl	12.8±1.9	12.8±2.0	12.5±1.8	-2.004	.045
Albumin, g/dl	3.9±0.5	3.9±0.5	3.8±0.5	-.912	.373
Ward types, n(%)				69.993	<.001
General unit	520(47.7)	433(46.4)	87(55.8)		
Integrated nursing care service	508(46.6)	467(50.0)	41(26.3)		
Intensive care unit/ Stroke unit	62(5.7)	34(3.6)	28(17.9)		
Insurance types, n(%)				1.55	.282
National health insurance	1005(92.2)	865(92.6)	140(89.7)		
Medical-aid	85(7.8)	69(7.4)	16(10.3)		
Residential areas, n(%)				0.89	.377
Urban	492(45.1)	416(44.5)	76(48.7)		
Rural	598(54.9)	518(55.5)	80(51.3)		
Stroke types, n(%)				8.978	<.001
Subarachnoid hemorrhage	115(10.6)	99(10.6)	16(10.2)		
Intracranial hemorrhage	156(14.3)	120(12.8)	36(23.1)		
Transient Ischemic attack	819(75.1)	715(71.6)	104(66.7)		
Admission routes, n(%)				10.53	.002
Emergency room	699(64.1)	581(62.2)	118(75.6)		
Outpatient department	391(35.9)	353(37.8)	38(24.4)		
Admission states, n(%)				17.118	<.001
On foot	397(36.4)	363(38.9)	34(21.8)		
Wheelchair	262(24.0)	218(28.3)	44(28.2)		
Bed	431(39.5)	353(37.8)	78(50.0)		

Hypertension, n(%)	614(56.3)	515(55.1)	99(63.5)	3.775	.064
Diabetes, n(%)	276(25.3)	229(24.5)	47(30.1)	2.27	.164
Dyslipidemia, n(%)	417(38.3)	369(39.5)	48(30.8)	4.344	.047
Arrhythmia, n(%)	83(7.6)	59(6.3)	24(15.4)	15.701	<.001
Coronary artery disease, n(%)	47(4.3)	41(4.4)	6(3.8)	0.093	.923
Osteoporosis, n(%)	35(3.2)	27(2.9)	8(5.1)	2.17	.222
Degenerative spinal diseases, n(%)	41(3.8)	26(2.8)	15(9.6)	17..3	<.001
Cerebral neuro degenerative diseases, n(%)	58(5.3)	38(4.1)	20(12.8)	20.406	<.001
Medication, n(%)				25.348	<.001
None	563(51.6)	511(54.7)	52(33.3)		
Single	403(37.0)	321(34.4)	82(52.6)		
Poly	124(11.4)	102(10.9)	22(14.1)		
Alert mental status, n(%)	926(85.0)	792(84.8)	134(85.9)	0.12	.814
mRS	1.8±1.4	1.6±1.3	2.8±1.4	9.962	<.001
MBI	73.3±30.4	76.1±30.1	56.7±26.7	-7.567	<.001
NIHSS	4.2±6.0	4.0±6.2	5.3±4.1	3.334	<.001

예측 성능 평가 결과

1) MFS 예측 성능 평가 결과

MFS의 단독 예측 성능 결과는 AUROC는 0.76(민감도;0.72, 특이도;0.74)으로 확인되었으며 절삭값(cut-off value)은 42.50점으로 확인되었다(Figure 9).

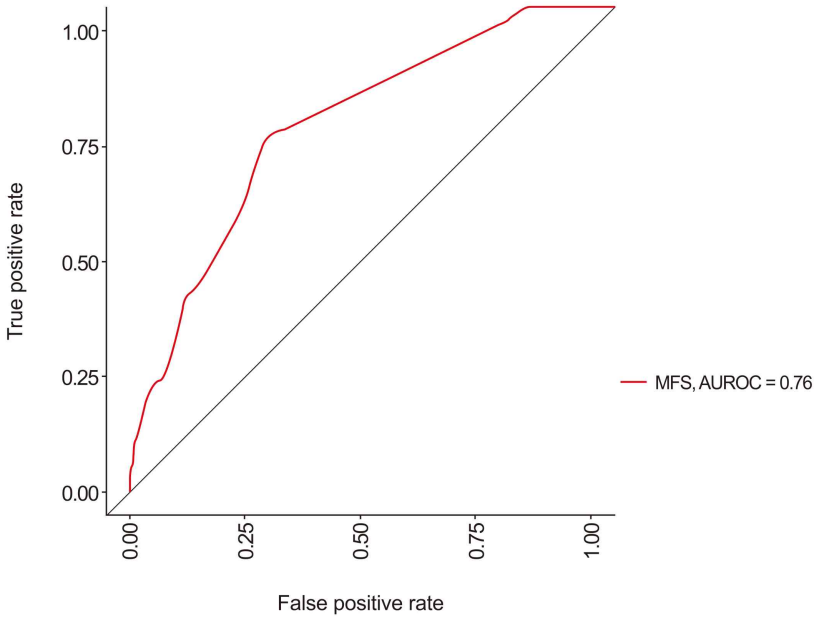

Figure 9. Prediction performance of MFS

2) 기계학습 알고리즘 예측 성능 평가 결과

적용된 4개의 기계학습 알고리즘 중 XGB가 AUROC 0.90으로 가장 좋은 예측력을 보여 주었다. F1 스코어는 0.63으로 XGB가 가장 높은 수치를 보여 주었다. 그 다음으로 RF가 AUROC 0.88, 정확도 90.55 및 F1 스코어 0.56으로 우수한 예측 성능을 보여 주었다. SVM도 AUROC 0.88, 정확도 91.66 및 F1 스코어 0.56으로 우수한 예측 성능을 보여 주었다. 적용된 모든 기계학습 알고리즘은 MFS 단독에 비해서 더 향상된 AUROC값을 보여 주었다. 한편 RLR 모델은 높은 AUROC값과 더불어 0.80으로 MFS의 0.76에 비해 더 높은 민감도 값을 보여 주었으며, 특이도 또한 0.83으로 MFS의 0.74에 비해 더 높았다 (Table 7, Figure 10).

Table 7. Predictive performance of machine learning algorithms

	RLR	SVM	RF	XGB
AUROC	0.88	0.88	0.89	0.90
Accuracy	82.62	91.66	90.55	91.46
F1 score	0.55	0.60	0.56	0.63
Sensitivity	0.80	0.50	0.46	0.55
Specificity	0.83	0.98	0.98	0.97
PPV	0.42	0.76	074	0.75
NPV	0.96	0.93	0.92	0.93

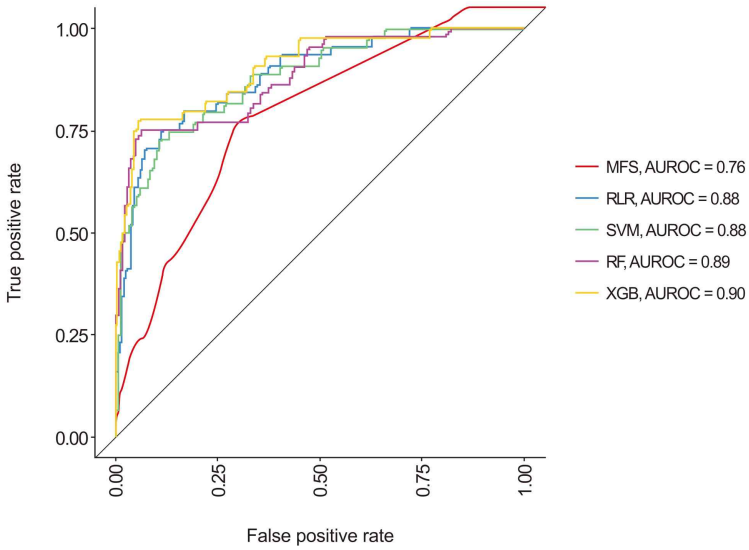

Figure 10. Sensitivity and specificity of machine learning algorithms

낙상위험 중요 변수

낙상위험 중요 변수를 모두 포함하여 분석한 결과 4개의 알고리즘 중 가장 높은 낙상위험 중요 변수로는 MFS, MBI, NIHSS, mRS로 나타났다. 4개의 기계학습 알고리즘에서 공통적으로 MFS, MBI, NIHSS가 중요 변수들로 확인되었다. 그 중에서 MFS가 가장 중요도가 높은 변수로 확인되었고 다음으로 뇌졸중의 상태를 나타내는 특성의 MBI, NIHSS가 높은 중요 변수들로 확인되었다. 또한 RLR, SVM, RF 3개의 알고리즘에서는 mRS가 중요 변수로 나타났다. 구체적으로 살펴보면 RLR에서는 mRS, MBI, NIHSS, 투약 순으로 나타났고 SVM에서는 MBI, mRS, NIHSS, 투약 순으로 나타났다. RF에서는 MBI, mRS, NIHSS, 병동 종류의 순으로 나타났고 XGB에서는 MBI, NIHSS, BMI, 헤모글로빈 수치 순으로 나타났다(Figure 11).

3개 이상의 기계학습 알고리즘에서 공통적으로 확인된 낙상위험 중요 변수를 제외한 변수는 다약제 복용 유무, 병동의 종류, 헤모글로빈, BMI 등이 주요 변수들에 포함되었다. 이 중 다약제 복용 유무는 RLR과 SVM 2개의 알고리즘에서 중요 변수로 확인되었다.

A. Regularized logistic regression

Feature	Value
MFS total	0.7918
mRS	0.7491
MBI	0.745
NIHSS	0.6984
Medication	0.6179

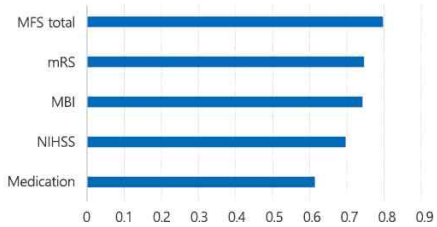

B. Support vector machines

Feature	Value
MFS total	0.7663
MBI	0.7341
mRS	0.7228
NIHSS	0.6821
Medication	0.6108

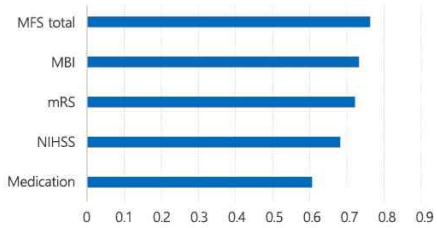

C. Random Forest

Feature	Value
MFS total	91.179
MBI	56.644
mRS	51.34
NIHSS	45.504
Ward type	23.477

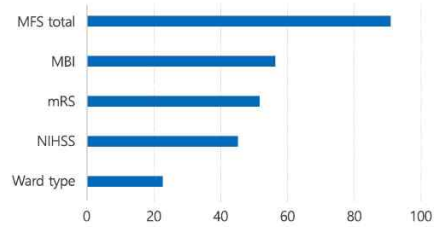

D. Extreme gradient boosting

Feature	Value
MFS total	0.13463
MBI	0.11386
NIHSS	0.09854
BMI	0.09323
Hemoglobin	0.08602

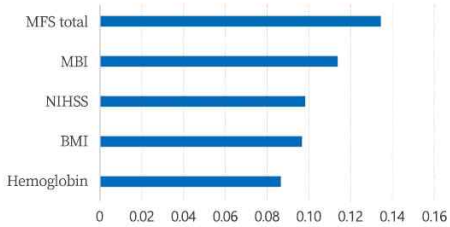

Figure 11. Fall risk factors ranked by feature importance

논의

본 연구에서는 전자의무기록을 활용하여 단일 의료기관의 급성기 뇌졸중 입원환자의 특성에 맞는 기계학습에 기반한 낙상 예측 알고리즘을 제안하였다.

급성기 뇌졸중 입원환자를 대상으로 낙상 예측과 낙상위험 중요 변수를 기계학습에 기반하여 진행한 연구는 처음 제안한 것으로 구체적인 연구 결과를 살펴보면 다음과 같다.

기계학습의 알고리즘을 통하여 낙상을 예측해 본 결과 RLR, SVM, RF, XGB가 높은 성능 결과를 보였다. 그 중에서 가장 높은 성능 결과를 보인 알고리즘은 XGB로 나타났다. 선행 연구에서는 기계학습의 알고리즘 중 결정트리, RF, SVM을 적용한 결과 SVM이 낙상 검출 성능이 높았다[80]. 기계학습을 통해서 전자의무기록을 이용한 입원환자의 낙상 예측 알고리즘을 파악한 연구에서는 배깅, RF, Adaboost, 결정트리와 MFS의 예측력 비교 결과 RF가 AUROC 0.90, 배깅이 0.89, Adaboost가 0.89로 MFS보다 훨씬 나은 예측력을 보였다[31]. 낙상위험도 평가도구와 XGB의 낙상 예측을 비교한 연구 결과에서도 XGB의 AUROC 0.700로 MFS의 AUROC 0.598보다 입원환자의 낙상 예측을 측정하는데 더 적합하고 민감도도 더 높다고 하였다[96]. 선행 연구에서 볼 수 있듯이 연구대상이 다른 차이점은 있지만 기계학습 알고리즘을 적용한 낙상 예측이 뛰어난 성능 결과를 보인 점은 공통된 점이라 할 수 있다. 따라서 본 연구에서 급성기 뇌졸중 입원환자의 기계학습 알고리즘 4개 중 XGB 알고리즘의 예측 성능 결과가 가장 높게 나타났다는 연구 결과는 임상 활용에 중요한 의의가 있다고 볼 수 있다. 또한 기계학습 알고리즘이 기존 MFS의 단독 예측 성능보다 더 높은 성능 결과를 보인 것 또한 의미가 있다고 할 수 있겠다.

기계학습에 기반한 급성기 뇌졸중 입원환자의 낙상위험 중요 변수에서는 4개의 알고리즘에서 전체 낙상위험 중요 변수 중 높은 위험도를 나타내는 5개 변수의 결과를 살펴보았다. 4개의 알고리즘 중 가장 높은 낙상위험 중요 변수로는 MFS, MBI, NIHSS, mRS 그리고 병동의 종류, 투약, 헤모글로빈, BMI가 중요 변수로 나타났다.

4개의 알고리즘 모두에서 가장 높은 낙상위험 중요 변수는 MFS였다. 선행연구에서 낙상위험요인으로 낙상위험도 평가도구를 분석한 결과 전체 평균이 유의한 차이가 있었으며[4], 낙상군과 대조군의 낙상위험도 평가를 비교한 결과 유의한 차이를 보이고 있어 본 연구 결과와 일치하였다[97]. 급성기 뇌졸중 입원환자에서도 낙상위험도 평가도구는 낙상 발생을 잘 예측하는 도구 중 하나였다. 하지만 종합병원 입원환자의 낙상 위험도 평가의 세부 항목을 비교한 결과 일부 유의한 차이를 보이지 않는 항목과 실제 낙상은 저위험군에서 발생이 더 많았다는 보고도 있어 실제 낙상 발생의 비예측성은 여러 가지 이유로 기인된다고 볼 수 있겠다[4]. 지금까지 낙상위험도 평가도구는 연구 대상 및 다양한 요인에 따라 다르게 결과가 나타났으므로 대상자의 다양한 특성 및 환경적 특성을 모두 고려한 낙상 위험 예측요인을 파악하는 것은 중요하다[98]. 그러므로 낙상위험도 및 다양한 위험요인을 포함하여 낙상의 예측도를 높이기 위해서 입원환자의 질환으로 인한 특성과 치료적 조건을 고려하는 것도 매우 중요함을 확인할 수 있었다[9].

MFS 이외 4개의 알고리즘에서 MBI, NIHSS가 중요 변수로 나타났고 RLR, SVM, RF 3개의 알고리즘에서는 mRS가 중요 변수로 나타나 뇌졸중의 상태를 평가하는 특성이 낙상위험에 높은 영향을 끼친다고 볼 수 있었다. 선행 연구에서는 기계학습 알고리즘에 대한 낙상위험 중요 변수 관련 연구 결과는 없어서 본 연구의 결과와는 비교할 수 없었다. 그러나 기계학습 기반이 아닌 기존 연구에서는 뇌졸중 입원환자의 낙상 예측을 위한 평가 도구에서 MBI가 상

관관계가 있음을 보고하였고[99], 뇌졸중 입원환자의 낙상 유무와 MBI가 유의한 결과를 보였다는 연구 결과와 비교하면 본 연구 결과와 일치하였다[12]. 뇌졸중 입원환자의 심각도 및 중증도를 NIHSS로 평가한 결과에서 높은 낙상의 위험과 관련이 있다는 연구 내용은 본 연구와 유사한 결과를 보였다[100]. 또한 뇌졸중 입원환자의 mRS와 낙상위험의 상관관계를 비교한 연구에서는 mRS 2-3점이 낙상위험이 제일 높았고 mRS 4-5점으로 독립생활이 가능한 환자와 비교했을 때 낙상위험이 높았다는 결과와 유사한 결과를 보였다[62]. 이와 같이 질환의 특성을 반영한 뇌졸중 평가 척도가 낙상에 유의한 결과를 보인 것으로 볼 때 중증의 환자를 대상으로 한 의료기관의 경우 각 의료기관의 환경과 질병의 특성에 따른 낙상의 위험도를 분석하고 예측하는 것은 매우 중요한 부분이라 할 수 있겠다[4].

낙상위험 중요 변수 중에서 병동의 종류가 중요 변수로 나타났는데 간호간병통합서비스병동에서 유의한 차이를 보였다. 선행 연구에서는 간호간병통합서비스병동에서 오히려 낙상 발생률이 높았고[101] 간호간병통합서비스병동의 낙상 발생이 유의하지 않은 연구 결과가 있었다[102]. 그러나 간호간병통합서비스병동에서 낙상 발생률이 감소하였다는 연구 결과도 있으므로[103] 선행 연구들에서 일관된 결과를 보이지는 않고 있지만 본 연구는 간호간병통합서비스병동이 유의하게 낙상의 위험을 감소시킨다는 것을 뒷받침해 준 연구 결과를 보였다. 간호간병통합서비스병동은 노인환자의 입원 비율이 증가하고 보호자의 간병 부담 감소 등 긍정적인 효과가 있는 반면 간호사의 부담은 가중되고 있고 환자 안전 중 낙상에 대한 책임이 더 많이 요구되고 있는 것이 현실이다[101]. 본 연구에서는 신경학적 손상이 있는 중증 환자임을 감안하여 간호간병통합서비스병동에서 질환별 특성을 고려한 낙상 예방 활동을 집중적으로 하고 있었던 점을 고려하여야 하고 추가적인 연구가 필요하다 할 수 있겠다.

다음으로 약제 복용 유무가 중요 변수로 나타났는데 선행 연구에서 약물의 종류가 낙상 발생에 영향을 미치는 요인으로는 진통제, 수면제, 항부정맥제, 혈관확장제, 근이완제를 포함하는 약물 복용이 유의하게 영향을 미치는 요인으로 나타났다[104]. 또한 중추신경계 약물이 낙상에 중요한 요인이라는 연구 결과가 있었고[9], 2가지 이상 약물 사용의 경우 낙상 위험이 더 높았다는 연구 결과가 있어 본 연구 결과와 유사한 결과를 보였다[105]. 입원환자를 대상으로 한 낙상의 다양한 연구에서와 같이 약물 투여는 낙상 위험요인으로 알려져 있고 낙상 위험군별, 질환별 약물 종류는 다르게 조사될 수 있다. 특히 급성기 뇌졸중 입원환자는 동반 질환에 따른 약물을 복용 중이고 추가적으로 중추신경계 약물, 진정제, 마약성 진통제 등 많은 약물이 투여되고 있어 낙상의 위험도와 관련이 높다고 할 수 있다.

급성기 뇌졸중 입원환자의 낙상위험 중요 변수로 BMI가 도출되었으나 관련한 선행 연구는 없어 비교가 어렵다. 만성 뇌졸중 입원환자를 대상으로 한 연구에서 BMI가 유의한 차이를 보인 연구 결과가 있었고[106] 종합병원 입원환자의 낙상 발생에 영향을 미치는 요인으로 BMI가 유의한 차이를 보였다라는 연구가 있어 일치한 결과를 보였다[104]. 급성기 뇌졸중 입원환자의 BMI는 정상 체중보다 낮은 환자 혹은 신체 운동기능이 약화된 환자의 경우 낙상이 많이 발생할 수 있다는 일반적인 인식과도 동일한 결과로 해석할 수 있겠다.

급성기 뇌졸중 입원환자의 낙상위험 중요 변수로 헤모글로빈 수치가 중요 변수로 나타났다. 선행 연구에서는 급성기 뇌졸중 입원환자의 낙상위험 중요 변수에 관련한 연구는 없어 비교가 어렵다. 급성기 병원에 입원환자의 낙상위험 요인으로 빈혈이 유의한 차이가 있다는 보고가 있어 유사한 연구 결과를 확인할 수 있었다[107]. 그러나 급성기 병원에 입원한 노인 환자를 대상으로 한 연

구에서 영양상태를 반영하는 알부민 수치는 유의한 차이를 보였고 헤모글로빈 수치에서는 유의한 차이를 보이지 않았다는 보고가 있어 영양상태가 낙상과 관련이 있음을 보여주기는 하였지만 본 연구와 일치하지 않았다[97]. 본 연구에서는 출혈을 동반할 수 있는 뇌졸중 입원환자임을 고려하여야 하고 추가적인 연구가 필요하다 할 수 있겠다.

본 연구는 급성기 뇌졸중 입원환자의 낙상에 대해 낙상위험도와 다양한 낙상위험요인을 적용하여 분석하고 예측하였다. 급성기 뇌졸중 입원환자의 낙상위험 중요 변수에서 볼 수 있듯이 질환의 특성에 따른 도구가 중요한 변수로 나타났고 이를 통해 낙상 예측이 더 정확해짐을 확인할 수 있었다. 또한 의료기관의 특성 및 질환별 특성에 따라서 낙상 위험 중요 변수 및 예측이 다르다는 연구 결과를 입증하는 것이라 할 수 있다. 이처럼 기계학습 알고리즘은 특정 환경에 적합한 데이터를 사용하여 더욱 정확성을 높일 수 있고 예측이 더 정교해질 수 있다는 것을 확인한 결과이다[28].

임상 간호사들이 낙상에 대한 스트레스가 많고 낙상위험도 평가도구만을 사용하여 중재하고 예측하는 것만으로는 많은 한계를 느끼고 있다. 또한 개별환자마다 질환별 특성에 따른 낙상위험요인을 확인하는 것은 많은 시간을 요구하며 과도한 업무가 될 수밖에 없다. 그리고 실제적으로 임상에서 간호사들이 낙상에 대한 중재를 위해 환자의 위험요인을 각각 검색하고 찾아내어 간호를 한다는 것은 현실적으로 어렵다. 이러한 단점을 해결하는 방안으로 기계학습을 통해서 낙상 예측에 적합한 알고리즘을 사용하여 쉽고 빠르게 예측 결과를 확인할 수 있다는 것은 큰 임상적 의의가 있다고 할 수 있다. 또한 간호사들의 빠르고 보다 정확한 낙상 예측을 통하여 낙상에 대한 간호 중재를 할 수 있고 더 나아가 낙상 발생이 감소하는 결과를 가져올 것이라 기대한다.

결론 및 제언

결론

본 연구에서는 단일 의료기관의 급성기 뇌졸중 입원환자를 대상으로 기계학습에 기반하여 낙상위험을 예측하였다.

급성기 뇌졸중 입원환자의 기계학습을 통한 4개 알고리즘의 성능 결과를 보면 MFS 단독 낙상 예측과 4개의 기계학습 알고리즘의 낙상 예측을 비교하였을 때 4개의 기계학습 알고리즘의 낙상 예측이 MFS 단독 예측보다 높은 결과를 보였다. 그리고 전체 성능 결과에서도 4개의 알고리즘이 MFS보다 모두 높은 예측을 보였고 그 중에서 가장 높은 예측력을 보인 알고리즘은 XGB였음을 확인하였다.

급성기 뇌졸중 입원환자의 기계학습을 통한 4개의 알고리즘에서 낙상위험 중요 변수로는 MFS가 가장 높게 나타났고 그 외에도 mRS, NIHSS, MBI와 같은 뇌졸중 환자의 상태를 평가하는 척도가 중요 변수로 작용하고 있음을 확인할 수 있었다.

이와 같이 기계학습을 활용한 낙상 예측 알고리즘은 특화된 질환의 상태를 포함하여 낙상위험도를 분석하고 예측하는 데 있어 쉽게 적용 가능하며, 더 정확하고 빠른 시간 내에 효율적인 낙상 예측을 가능하게 해준다는 점에서 임상적 의의가 크다고 할 수 있다.

급성기 뇌졸중 입원환자를 대상으로 기계학습 알고리즘을 활용하여 실제적으로 임상에 적용하게 된다면 입원 시 질환의 특성에 따른 개별 환자에 대한 낙상의 빠른 예측을 통해 간호사들이 낙상의 위험도를 개별적으로 파악하는 데 소요되는 시간을 줄이고 더 정확한 예측을 통하여 낙상에 대한 중재나 관리가 효율적으로 이루어질 것이라 사료된다.

제언

본 연구 결과를 바탕으로 다음과 같이 제언하고자 한다.

첫째, 단일 의료기관의 특정 질환에 대한 연구이므로 결과를 일반화하기에 제한점이 있다. 향후 여러 의료기관의 빅데이터를 활용한 결과의 추후 검증 및 반복 연구가 필요하다.

둘째, 전자의무기록만을 이용하여 낙상위험 중요 변수 및 예측을 진행하였다. 다양한 낙상위험 변수를 고려하였음에도 불구하고 잠재적인 질환별 특성을 고려한 낙상위험을 찾아내는 연구가 필요하며 전자의무기록 이외에 낙상위험 변수에 의한 정보는 포함할 수 없었으므로 추가적인 연구가 필요하다.

셋째, 각 의료기관의 특정 질환별 낙상위험 중요 변수 및 예측을 위한 반복 연구가 지속적으로 이루어져야 할 것이며 향후 낙상 예방 중재 프로그램 개발 및 효과를 검증하는 연구가 필요하다.

넷째, 다양한 낙상 예측 알고리즘의 반복 연구를 통하여 최적의 알고리즘을 설계하고 전자의무기록시스템과 연계하여 임상에 활용할 수 있는 프로그램을 개발하고 실무에 적용해 볼 것을 제언한다.

참고문헌

1. Nakatani H, Nakao M, Uchiyama H, Toyoshiba H, Ochiai C. Predicting Inpatient Falls Using Natural Language Processing of Nursing Records Obtained From Japanese Electronic Medical Records: Case-Control Study. JMIR Medical Informatics. 2020;8(4):e16970. https://doi.org/10.2196/16970
2. Ministry of Health and Welfare, Korea Institute for Healthcare Accreditation. Korean Patient Safety Incident Report 2020[Internet]. Seoul: Korea Institute for Healthcare Accreditation. 2021[cited 2021 May 28]. Available from: https://www.kops.or.kr/portal/board/statAnlrpt/boardList.do
3. Bergland A, Wyller TB. Risk factors for serious fall related injury in elderly women living at home. Injury Prevention. 2004;10:308-313. http://dx.doi.org/10.1136/ip.2003. 004721
4. Jang IS, Lee S. Fall Risk Factors and Characteristics of an Acute Hospital Setting across Clinical Departments. Korean Academy Fundamental Nursing. 2014;21(3):264-274. https://doi.org/10.7739/jkafn.2014.21.3.264
5. Coussement J, De Paepe L, Schwendimann R, Denhaerynck K, Dejaeger E, Milisen K. Interventions for preventing falls in acute-and chronic-care hospitals: A systematic review and meta-analysis. American Geriatric Society. 2008;56(1):29-36.
6. National Patient Safety Agency. Slips, trips and falls in hospital [Internet]. London, UK: Author; 2007 [cited 2017 January 1]. Available

from: http://www.npsa.nhs.uk

7. Kim CG, Suh MJ. An Analysis of Fall Incidence Rate and Its Related Factors of Fall in Inpatients. Quality Improvement in Health Care. 2002;9(2):210-228.

8. Nyberg L, Gustafson Y. Fall prediction index for patients in stroke rehabilitation. Stroke. 1997;28(4):716-721. http://doi.org/10.1161/01.str.28.4.716

9. Choi EH, Ko MS, Yoo CS, Kim MK. Characteristics of Fall Events and Fall Risk Factors among Inpatients in General Hospitals in Korea. Korean Clinical Nursing Research. 2017;23(3):350-360. https://doi.org/10.22650/JKCNR.2017.23.3.350

10. Belgen B, Beninato M, Sullivan PE, Narielwalla K. The association of balance capacity and falls self-efficacy with history of falling in community-dwelling people with chronic stroke. Archives of Physical Medicine an Rehabilitation. 1991;87(4):554-561. http://doi.org/10.1016/j.apmr.2005.12.027

11. Sze K, Wong E, Leung HY, Woo J. Falls among chinese stroke patients during rehabilitation. Archives of Physical Medicine and Rehabilitation. 2001;82(9):1219-25. https://doi.org/10.1053/apmr.2001.25094

12. Kwon MJ. The Fall Circumstance and Related Factors Associated with Fall in the Stroke Patients. Korean Society of Physical Therapy. 2008;20(3):19-28.

13. Tutuarima JA, van der Meulen JH, de Haan RJ, van straten A, Limburg M. Risk factors for falls of hospitalized stroke patients. Stroke. 1997;28(2):297-301. https://doi.org/10.1161/01.STR.28.2.297

14. Graafmans WC, Ooms ME, Hofstee HM, Bouter LM, Lip P. Falls in the elderly: a prospective study of risk factors and risk profiles. American Journal of Epidemiology. 1996;143(11):1129-36.
15. Joint Commission International. 1951 [Internet]. United States standards, International Patient Safety Goals. United States. [cited 2022 January 7]. Available from: https://www.jointcommissioninternational.org
16. Hendrich AL, Bender PS, Nyhuis A. Validation of the hendrich II fall risk model: a large concurrent case/control study of hospitalized patients. Applied Nursing Research. 2003;16(1):9-21. https://doi.org/10.1053/apnr.2003.016009
17. Morse JM, Morse RM, Tylko SJ. Development of a scale to identify the fall-prone patient. Canadian Journal on Aging. 1989;8(4):366-377. https://doi.org/10.1017/S0714980800008576
18. Nunan S, Brown Wilson C, Henwood T, Parker D. Fall risk assessment tools for use among older adults in long-term care settings: A systematic review of the literature. Australasian journal on ageing. 2018;37(1):23-33. https://doi.org/10.1111/ajag.12476
19. Cho IS. Developing a predictive and proactive prevention service for inpatient falls using clinical analytics. R&D Report. Incheon: Ministry of Health and Welfare;2017 August. Report No.: HI15C1089
20. Najafpour Z, Godarzi Z, Arab M, Yaseri M. Risk Factors for Falls in Hospital In-Patients: A Prospective Nested Case Control Study. International Journal Health Policy Management. 2019;8(5):300-306. http://doi.org/10.15171/ijhpm.2019.11
21. Pelczarski K, Schoelles K, Wallace LC, Neumann P. Preventing Falls in

Hospitals: a toolkit for improving quality of care. : Agency for Health care Research and Quality; 2013 January.
Report No.: HHSA290201000017I TO #1

22. Patterson BW, Engstrom CJ, Sah V, Smith MA, Mendonca EA, Pulia MS, et al. Training and Interpreting Machine Learning Algorithms to Evaluate Fall Risk After Emergency Department Visits. Medical Care. 2019;57(7):560-566 http://doi.org/10.1097/MLR.0000000000001140
23. Jung, HS. Development of a clinical decision support system for fall prediction and prevention using clinical data. [dissertation]. [Seoul]: Seoul National University; 2019. 116p
24. Park HA. Big data analytics and evidence-based patient safety event prediction, prevention, and reporting system development. Seoul: Seoul National University; 2018 May. Report No.: 1711052198.
25. Starke G, De Clercq E, Elger BS. Towards a pragmatist dealing with algorithmic bias in medical machine learning. Medicine Health Care Philosophy. 2021;24:341-349. http://doi.org/10.1007/s11019-021-10008-5
26. Schwartz JT, Gao M, Geng EA, Mody KS, Mikhail CM, Cho SK. Applications of Machine Learning Using Electronic Medical Records in Spine Surgery. Neurospine. 2019;16(4):643-653.
http://doi.org/10.14245/ns.1938386.193
27. Statistics Korea. 2020 life tables for Korea [Internet]. Seoul:Statistics Korea. [cited 2022 January 17]. Available from: http://wiki.hash.kr/
28. Woo YC, Lee SY, Choi W, Ahn CW, Baek OK. Trend of Utilization of Machine Learning Technology for Digital Healthcare Data Analysis. Electronics and Telecommunications Research institute.

2019;34(1):98-110. http://doi.org/10.22648/ETRI.2019.J.340109

29. Kim IN, Kim DH, HEO SS, Lee JK. Machine learning based Fall Detection. Korea Information Processing Society. 2020;27(1):547-550. https://doi.org/10.3745/PKIPS.y2020m05a.547

30. Panyakaew P, Pornputtapong N, Bhidayasiri R. Using machine learning-based analytics of daily activities to identify modifiable risk factors for falling in Parkinson's disease. Elsevier. 2021;82:77-83. https://doi.org/10.1016/j.parkreldis.2020.11.01

31. Lindberg DS, Prosperi M, Bjarnadottir RI, Thomas J, Crane M, Chen Z, et al. Identification of important factors in an inpatient fall risk prediction model to improve the quality of care using EHR and electronic administrative data: A machine-learning approach. International Journal of Medical Informatics. 2020;143:104272. http://doi.org/10.1016/j.ijmedinf.2020.104272

32. Wang L, Xue Z, Ezeana CF, Puppala M, Chen S, Danforth RL et al. Preventing inpatient falls with injuries using integrative machine learning prediction: a cohort study. NPJ Digital Medicine. 2019;2:127. http://doi.org/10.1038/s41746-019-0200-3

33. Young AJ, Hare A, Subramanian M, Weaver JL, Kaufman E, Sims C. Using Machine Learning to Make Predictions in Patients Who Fall. Elsevier. 2021;257:118-127. https://doi.org/10.1016/j.jss.2020.07.047

34. Introduction of Korean Academy of Rehabilitation Medicine: Korean Academy of Rehabilitation Medicine[Internet]. Seoul: Korean Academy of Rehabilitation Medicine 1971[cited 2022 October 15]. Available from: https://www.karm.or.kr

35. Lamb SE, Jorstad-Stein EC, Hauer K, Becker C. Development of a common outcome data set for fall injury prevention trials: the prevention of falls network europe consensus. Journal of the American Geriatric Society. 2005;53(9):1618-1622. http://doi.org/10.1111/j.1532-5415.2005.53455.x
36. Fuller GF. Falls in the elderly. American Academy of Family Physicians. 2000;61(7):2159-2168.
37. Kim CG, Suh MJ. An Analysis Fall Incidence Rate and lts Related Factors of Fall in Inpatients. Korean Society of Quality Assurance in Health Care. 2002;9(2):210-228.
38. Hospital Nurses Association. Preventing Falls in Hospitals: Systematic Approach for Improving Quality of Care. Evidence-Based Clinical Nursing Practice Guideline[Internet]. Seoul: 2008. [cited 2018 October 10]. Available from: https://khna.or.kr/home/pds/practiceGuidelines.php#practiceStudy
39. Samuel AL. Some Studies in Machine Learning Using the Game of Checkers. IBM Journal of Research and Development. 1959;44:206-226.
40. Choi SJ. A Study on Application of Machine Learning for Occupational Safety[dissertation].[Ulsan]: Ulsan University; 2021. 77p.
41. Hayes N. Prevention of falls among older patients in the hospital environment. British Journal of Nursing. 2004;13(15):896-901. http://doi: 10.12968/bjon.2004.13.15.15525
42. Lee AS, Yoon CK. A study on nurses' perception to the patient safety in hospital. Korean Public Health Research. 2010;36(2):73-82.
43. Evans , Hodgkinson B, Lambert L, & Wood J. Fall risk factors in the

hospital setting: A systematic review. International Journal of Nursing Practice. 2001;7(1):38-45. https://doi.org/10.1046/j.1440-172x.2001.00269.x

44. Kim YL, Jeong SH. Effects of nursing interventions for fall prevention in hospitalized patients: A meta-analysis. Korean Academy of Nursing. 2015;45(4):469 - 482. http://doi.org/10.4040/jkan.2015.45.4.469

45. Hur JY, Kim HJ. Relationship of risk factors, knowledge and attitude to falls in elderly patients. Korean Gerontological Nursing. 2009;11(1):38-50.

46. Mottillo S, Filion KB, Genest J, Joseph L, Pilote L, Poirier P, et al. The metabolic syndrome and cardiovascular risk a systematic review and meta-analysis. American College of Cardiology. 2010;56(14):1113-1132. https://doi.org/10.1016/j.jacc.2010.05.034

47. Suzuki T, Yoshida H, Hashimoto T, Yoshimura N, Fujiwara S, Fukunaga M, et al. Case-control study of risk factors for hip fractures in the Japanese elderly by a mediterranean osteoporosis study(MEDOS) questionnaire. Bone. 1997;21:461-7. https://doi.org/10.1016/s8756-3282(97)00179-8

48. Brott T, Adams HP JR, Olinger CP, Marler JR, Barsan WG, Biller J, et al. Measurements of acute cerebral infarction: a clinical examination scale. Stroke. 1989;20:864-870.

49. Rapport LJ, Websster JS, Flemming, KL, Lindberg, JW, Go Dlewski MC, Brees JE, et al. Predictors of fall among right-hemisphere stroke patients in the rehabilitation setting. Archives of Physical Medicine and Rehabilitation. 1993;74(6):621-626

50. Kang YO, Song RY. Validation of Fall Risk Assessment Scales among

Hospitalized Patients in South Korea using Retrospective Data Analysis. Korean Journal of Adult Nursing. 2015;27(1):29-38. http://dx.doi.org/10.7475/kjan.2015.27.1.29

51. World Health Organization. Conceptual framework for the international classification for patient safety version 1.1: Final technical report [Internet]. Geneva: World Health Organization; 2010. [cited 2009 February]. Available from: https://apps.who.int/iris/handle/10665/70882
52. Cho I, Kim J, Chae J, Jung M, Kim YH. Comparison of Content Coverage of Domestic and International Inpatient Falls Prevention Guidelines Using Standard Nursing Terminologies. Korean Society of Adult Nursing. 2018;30(6):622-633
53. Cho IS, Park KH, Kim EM, Seo MH. Evidence-based Clinical Nursing Practice Guideline for Management of Inpatient Falls: Adopting the Guideline Adaptation Process. Korean Academy of Fundamentals of Nursing. 2020;12(1):40-51. https://doi.org/10.7739/jkafn.2020.27.1.40
54. Choi HY, Lee HY, Kim SB, Shin WC. Clinical Assessment in Stroke Patients:Introduction of Neurologic Stroke Scales. Neuro intervention. 2009;4:74-86.
55. Mayo NE, Korner-Bitensky N, Levy AR. Risk factors for fractures due to falls. Archives of Physical Medicine and Rehabilitation. 1993; 74(9):917-921.
56. Lee HS, Choi JH. Correlation Between BBS, FRT, STI, TUG, MBI, and Falling in Stroke Patients. Korean Society of Physical Therapy. 2008;20(4):1-8.
57. Loewen SC, Anderson BA. Reliability of the Modified Motor

Assessment and the Barthel Index. Physical Therapy. 1988;68(7):1077-1081.

58. Granger CV, Albrecht GL, Hamilton BB. Outcome of comprehensive medical rehabilitation: Measurement by pulses profile and the barthel Index. Archives of Physical Medicine & Rehabilitation. 1979;60(4):145-154.

59. Persson CU, Hansson PO. Determinants of falls after stroke based on data on 5065 patients from the Swedish Väststroke and Riksstroke Registers. Scientifc Reports. 2021;11(15):24035. https://doi.org/10.1038/s41598-021-03375-9

60. Wei WE, De Silva DA, Chang HM, Yao J, Matchar DB, Young SHY et al. Post-stroke patients with moderate function have the greatest risk of falls: a National Cohort Study. BMC Geriatrics. 2019;19:373. https://doi.org/10.1186/s12877-019-1377-7

61. Foster EJ, Barlas RS, Bettencourt-Silva JH, Clark AB, Metcalf AK, Bowles KM et al. Long-term factors associated with falls and fractures poststroke. Frontiers in Neurology. 2018;4(9):1-9. https://doi.org/10.3389/fneur.2018.00210

62. Callaly EL, Ni Chroinin D, Hannon N, Sheehan O, Marnane M, Merwick A et al. Falls and fractures 2 years after acute stroke: the North Dublin population stroke study. Age Ageing. 2015;44(5):882-886. https://doi.org/10.1093/ageing/afv093

63. Lim JY, Jung SH, Kim W-S, Paik N-J. Incidence and risk factors of poststroke falls after discharge from inpatient rehabilitation. Elsevier. 2012;4(12):945-953. https://doi.org/10.1016/j.pmrj.2012.07.005

64. Van Swieten JC, Koudstaal PJ, Visser MC, Schouten HJ, van Gijn J. Interobserver agreement for the assessment of handicap in stroke patients. Stroke. 1988;19:604-607.

65. National Institute for Health and Care Excellence. Fall: Assessment and prevention of falls in older people. NICE Clinical Guidelines [Internet]. London: NICE; 2013 [cited 2018 Feb 22]. Available from: http://www.ageingwellinwales.com/Libraries/Documents/Assessment-and-Prevention-of-Falls-in-Older-People-NICEGuidelines.pdf

66. Lam CF, Hsieh SY, Wang JH, Pan HS, Liu XZ, Ho YC et al. Incidence and characteristic analysis of in-hospital falls after anesthesia. Perioperative Medicine. 2016;5(1):11. https://doi.org/10.1186/s13741-016-0038-z

67. Badillo S, Banfai B, Birzele F, Davydov II, Hutchinson L, Kam-Thong T et al. An Introduction to Machine Learning. Clinical Pharmacology & Therapeutics. 2020;107(4):871-885. https://doi:10.1002/cpt.1796

68. Noble WS. What is a support vector machine?. Nature Biotechnology. 2006;24(12):1565-1567. https://doi:10.1038/nbt1206-1565

69. Smola AJ, Schölkopf B. A tutorial on support vector regression. Statistics and Computing. 2004;14:199-222. https://doi:10.1023/b:Stco.0000035301.49549.88

70. Hawkins DM. The Problem of Overfitting. Chemical Information and Computer Sciences. 2003;44:1-12. https://doi:10.1021/ci0342472

71. Park DH, Jeong EH, Kim HJ, Pyun HW, Kim, HM, Choi YJ et al. Machine Learning-Based Three-Month Outcome Prediction in Acute Ischemic Stroke: A Single Cerebrovascular-Specialty Hospital Study in

South Korea. Diagnostics. 2021;11(10):1909.
https://doi:10.3390/diagnostics11101909

72. Hajipour F, Jozani MJ, Moussavi Z. A comparison of regularized logistic regression and random forest machine learning models for daytime diagnosis of obstructive sleep apnea. Medical & Biological Engineering & Computing. 2020;58:2517-2529.
https://doi:10.1007/s11517-020-02206-9

73. Yang L, Wu H, Jin X, Zheng P, Hu S, Xu X et al. Study of cardiovascular disease prediction model based on random forest in eastern China. Scientific Reports. 2020;10:5245.
https://doi:10.1038/s41598-020-62133-5

74. Rigatti SJ. Random Forest. Insurance Medicine. 2017;47:31-39.
https://doi:10.17849/insm-47-01-31-39.1

75. Dong X, Yu Z, Cao W, Shi Y, Ma Q. A survey on ensemble learning. Frontiers of Computer Science. 2019;14(2):241-258.
https://doi:10.1007/s11704-019-8208-z

76. Natekin A, Knoll A. Gradient boosting machines, a tutorial. Frontiers in Neurorobotics. 2013;21(7):1-21. https://doi:10.3389/fnbot.2013.00021

77. Friedman JH. Greedy Function Approximation: A Gradient Boosting Machine. The Annals of Statistics. 2001;29:1189-1232.
https://doi.org/10.1214/aos/1013203451

78. Chen T, Guestrin C, XGBoost: A Scalable Tree Boosting System. KDD '16: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2016:785-794.
http://dx.doi.org/10.1145/2939672.2939785

79. Lee TK, Lee YH, J, Kim JM, Jung SM, Yang DW, Jo BG et al. Application Research of Algorithm for ADL and Falling Status Determination. Korean Society for Precision Engineering. 2017 May. 1072p
80. Kim IK, Kim DH, Noh S, Lee JK. 1D CNN and Machine Learning Methods for Fall Detection. Korea Information Processing Society. 2021;10(3):85-90. https://doi.org/10.3745/KTSDE.2021.10.3.85
81. Kim JM, Yoon KB, Sim JY, Park SY, Sin YS. Real-time fall detection using YOLOv3 algorithm. Korea Institute Of Communication Sciences. 2020;8:1294-1295. https://doi.org/10.1109/ICIVC50857.2020.9177447
82. Park SH, Kim EK. Systematic Review and Meta-analysis for Usefulness of Fall Risk Assessment Tools in Adult Inpatients. Korean Society for Health Promotion and Disease Prevention. 2016;16(3):180-191. http://dx.doi.org/10.15384/kjhp.2016.16.3.180
83. Aranda-Gallardo1 M, Morales-Asencio JM, Canca-Sanchez1 JC, Barrero-Sojo1 S, Perez-Jimenez C, Morales-Fernandez A, et al. Instruments for assessing the risk of falls in acute hospitalized patients: a systematic review and meta-analysis. BMC Health Services Research. 2013;13:122. http://www.biomedcentral.com/1472-6963/13/122
84. Eagle DJ, Salama S, Whitman D, Evans LA, Ho E, Olde J. Comparison of Three Instruments in Predicting Accidental Falls in Selected Inpatients in a General Teaching Hospital. Gerontological Nursing. 1999;25(7):40-45. https://doi.org/10.3928/0098-9134-19990701-14
85. Kim YJ. Nurses' Experience of Inpatients' Falls. Korean Academy of Fundamentals of Nursing. 2017;24(2):106-117.

https://doi.org/10.7739/jkafn.2017.24.2.106

86. Vaapio S, Salminen M, Vahlberg T, Sjösten N, Isoaho R, Aarnio P, et al. Effects of risk-based multifactorial fall prevention on health-related quality of life among the community-dwelling aged: A randomized controlled trial. Health and Quality of Life Outcomes. 2007;5:20. http://doi.org/10.1186/1477-7525-5-20

87. Kim YS, Choi KS. Fall Risk Factors and Fall Risk Assessment of Inpatient. Korean Society of Adult Nursing. 2013;25(1):74-82. https://doi.org/10.7475/KJAN.2013.25.1.74

88. Shanker, M, Hu MY, Hung MS. Effect of Data Standardization on Neural Network Training. Omega. 1996;24(4):385-397. https://doi.org/10.1016/0305-0483(96)00010-2

89. Kim HS. Development of the Machine Learning-based Employment Prediction Model for Internship Applicants : A Case of Myongji University [dissertation].[Seoul]: Myongji University; 2022. 91p.

90. Lee SY. Evaluation of the machine learning technique for ranking influential factors and optimizing the risk analysis of ground subsidence of the sewer pipes[dissertation].[Gwangju]: Chonnam National University; 2022. 129p.

91. Arlot S. Celisse A. A survey of Cross-validation Procedures for Model Selection. Statistics surveys. 2010;4:40-79.

92. Joo GH. Cardiovascular Disease Predictionusing the NHIS Big Data and Machine Learning [dissertation].[Kangwon]: Kangwon National University; 2022. 44p.

93. Fawcett T. An introduction to ROC analysis, Edited by Francesco

Tortorella. Pattern Recognition Letters. 2006;27(8):859-928. https://doi.org/10.1016/j.patrec.2005.10.010

94. Lee SH. EUS Multiple-Layer Hierarchical SVM for Imbalanced Data Classification[master's thesis]. [Seoul]: Hanyang University; 2018. 39p.

95. Kim HJ, Lee KB, Ryu SE, Hong SG. A Study on Classification Scheme Generation for Automatic Classification of Unlabeled Documents. Digital Contents Society. 2020;21(12):2211-2219. https://doi.org/10.9728/dcs.2020.21.12.2211

96. Hsu YC, Weng HH, Kuo CY, Chu TP, Tsai YH. Prediction of fall events during admission using eXtreme gradient boosting: a comparative validation study. Scientific Reports. 2020;10:1-7. https://doi.org/10.1038/s41598-020-73776-9

97. Noh HM. The relating factors of inpatient falls among hospitalized elderly for acute care: a case-control study[dissertation].[Seoul]: Hallym University; 2019. 47p.

98. Vassallo M, Stockdale R, Sharma JC, Briggs R, Allen S. A comparative study of the use of four fall risk assessment tools on acute medical wards. American Geriatrics Society. 2005;(53):1034-1038. http://dx.doi.org/10.1111/j.1532-5415.2005.53316.x

99. Won JI. A Comparison of Assessment Tools for Prediction of Falls in Patients With Stroke. Korean Research Society of Physical Therapy. 2014;21(2):37-47. http://dx.doi.org/10.12674/ptk.2014.21.2.037

100. Schmid AA, Kapoor JR, Dallas M, Bravata DM. Association between Stroke Severity and Fall Risk among Stroke Patients. Neuroepidemiology. 2010;34:158-162. https://doi.org/10.1159/000279332

101. Son JE, Park BK, Lee CH, Ahn KH, Kim JN, Park MH et al. Incidence Rate and Characteristics of Falls in Patients Using Comprehensive Nursing Care Service. Health Policy and Management. 2019;29(2):172-183. https://doi.org/10.4332/KJHPA.2019.29.2.172
102. Yoon SJ, Lee CK, Jin IS, Kang JG. Incidence of Falls and Risk Factors of Falls in Inpatients. Korean Society for Quality in Health Care. 2018;24(2):1-14. http://dx.doi.org/10.14371/QIH.2018.24.2.2
103. Park JH, Lee MH. Effects of nursing and care=giving integrated service on nursing work performance, nurses' job satisfaction and patient safety. Korean Academic Society of Home Health Care Nursing. 2017;24(1):14-22. https://doi.org/10.22705/jkashcn.2017.24.1.014
104. Choi EJ, Lee YS, Yang EJ, Kim, JH, Kim YH, Park HA. Characteristics and Risk Factors for Falls in Tertiary Hospital Inpatients. Korean Academy of Nursing. 2017;47(3):420-430. https://doi.org/10.4040/jkan.2017.47.3.42
105. Cho YS, Lee YO, Youn YS. Risk Factors for Falls in Tertiary Hospital Inpatients: A Survival Analysis. Korean Critical Care Nursing. 2019;12(1):57-70.
106. Park CS. A Study on the Relationship between Physical Function and Fall in Stroke Patients. Korean Health & Fundamental Medicine Society. 2021;14(1):10-17. https://doi.org/10.37152/kmhs.2021.14.1.10
107. Lee YJ. The fall related circumstance, fall risk factor, and fall predictors of inpatients of small and medium sized hospitals[master's thesis]. [Jinju]: Gyeongsang National University; 2015. 60p.

Analysis and prediction of fall risk in acute stroke inpatients based on machine learning*

Junhwa Choi

Department of Nursing
Graduate School, Kyungpook National University
Daegu, Korea
(Supervised by Professor Eunsuk Choi)

(Abstract)

Purpose: Falls are one of the most common accidents in medical institutions, which can threaten the safety of inpatients and negatively affect their prognosis. Among acute inpatients, those with cerebrovascular diseases are especially subject to very high fall rates due to motor disorders, sensory disorders, functional damage, reduced cognition levels, the presence of neurological diseases, and the use of compound medication. Currently, in most medical institutions, nurses assess all inpatients identically using fall risk assessment tools and provide nursing intervention according to the results. However, the fall risk assessment tool alone has limitations in identifying fall risk factors and predicting falls. Furthermore, it is very important for nurses to predict falls by identifying fall risks according to the characteristics of the patient's disease. Therefore, the purpose of this study is to identify important variables of fall risks by utilizing machine learning algorithms, find algorithms with high fall prediction rates, and provide basic data for future clinical use.

Method: This study was conducted as a retrospective study using electronic medical records. The study subjects were 8,462 patients who were hospitalized in a single medical institution, a general hospital specializing in cerebrovascular diseases. The patients under study were admitted in the institution from January 2016 to June 2022 with their main diagnosis being acute stroke. A total of 156 fall incidents were included in the study. The fall risk levels and factors of the patients were examined by studying their electronic medical records. Fall occurrence reports were examined by looking at written reports. R software version 4.2.1 was used for all statistical analysis and machine learning processes. In the nested case-control study setting, 936 patients were randomly selected after considering the dropout rate. This figure was six times the total

* A thesis submitted to the Council of the Graduate School of Kyungpook National University in partial fulfillment of the requirements for the degree of Ph.D in December 2022

number of falls. After exempting 2 patients, 934 patients were used in the final analysis. Univariable binary logistic regression model was used to check the prediction power of MFS. The prediction power was checked by assessing AUROC values. Data preprocessing was done for machine learning prediction. AUROC was used as the main value to assess prediction performance. Accuracy, F1 score, sensitivity, specificity, positive predictive value, and negative predictive value were also used for assessing prediction performance.

Result: In the comparison between the fall group and the control group of acute stroke inpatients, gender, weight, hemoglobin levels, wards with total nursing care service, hospitalization route, and hospitalization method showed significant results. Cerebral hemorrhage, arrhythmia among comorbidities, degenerative spinal diseases and neuro-degenerative diseases were found to be significant factors. In addition, both single and compound drug administration rates, MFS, mRS, NIHSS and MBI showed significant results. As for the characteristics of falls in acute stroke inpatients, the majority of falls occurred in the ward and in the hospital room. In many cases, falls were not accompanied by injuries. Falls occurred mainly during irregular hours and occurred more on weekends than on weekdays. MFS was the most important variable for fall risk in the four machine learning algorithms, followed by MBI and NIHSS. Additionally, MFS, mRS, MBI and NIHSS showed up as important variables of fall risks in three machine learning algorithms. The predictive performance of MFS alone showed AUROC of 0.76. Looking at the prediction performance results of the machine learning algorithms, XGB had the highest AUROC of 0.90, followed by RF with 0.89, SVM with 0.88, and RLR with 0.88.

Conclusion: This study proposed a fall prediction algorithm based on machine learning that is tailored to the characteristics of acute stroke inpatients in a single medical institution using electronic medical records. This study is the first of its kind. The different assessment tool used depending to the characteristics of the disease appeared as an important variable. The study confirmed that different assessment tools allowed higher accuracy of fall predictions. In clinical practice, it is practically difficult for nurses to check and intervene fall risks by considering the characteristics of each patient's disease. The fall prediction algorithm using machine learning has much clinical significance in that, 1) it can be easily applied in analyzing and predicting fall risks, including the state of specific diseases, and 2) it enables more accurate and efficient fall prediction in a shorter time. In addition, by enabling nurses to more quickly and more accurately predict fall risks, the fall prediction algorithm using machine learning will lead to efficient nursing intervention and management of falls, which will ultimately result in reducing the occurrence of falls.

Keyword: Machine learning, Fall risk, Fall prediction

부록

부록 1. 생명윤리심의위원회 심의 결과 통지서

PSSH Institutional Review Board [별지 제9-2호 서식]

	결과통지서		
과제번호	PSSH0475-202108-HR-016	관리번호	04

귀하께서 2022년 12월 02일 에 신청한 기계학습에 기반한 급성기 뇌졸중 입원 환자의 낙상위험도 분석 및 예측에 대하여 에스포항병원 기관생명윤리위원회 및 임상시험심사위원회에서 다음과 같이 결정하였음을 통지합니다.

과 제 명	기계학습에 기반한 급성기 뇌졸중 입원 환자의 낙상위험도 분석 및 예측					
시험/연구 책임자	성 명	최준화	소 속	의료질관리실	직 위	차장

심사 대상	☐ 임상시험/연구계획변경	☐ 지속심사/중간보고	
	☐ 중대한 이상반응	☐ 위반/이탈사례	
	☐ 임상시험/연구(조기)종료/결과보고	■ 기타 (과제명)	
심사 일자	2022 년 12 월 5 일	심사 장소	
심사 의견	사소한 변경에 해당되어 변경 승인		
심사된 서류	연구계획변경심사신청서, 변경대비표, 변경된 연구계획서, 변경된 연구계획서 요약		

2022 년 12 월 05 일

에스포항병원 기관생명윤리위원장 임상시험심사위원장 (인)

본 확인서에 기재된 사항은 에스포항병원 기관생명윤리위원회 및 임상시험심사위원회에 기록된 내용과 일치함을 증명합니다. 본 위원회는 생명 윤리 및 안전에 관한 법률, 의약품 임상시험관리기준 및 의료기기 임상시험관리기준 및 등 관련 법규를 준수합니다. 본 임상시험 및 연구와 이해상충(Conflict of Interest)이 있는 위원이 있을 경우 연구의 심사에서 배제합니다. 본 통지서의 사본은 에스포항병원 기관생명윤리위원회 및 임상시험심사위원회에서 보관합니다.

부록 2. Modified Barthel Index(MBI)

Modified Barthel Index

Registration Number		Name		Sex/Age		Date	

Item	Unable to perform task	Substantial help required	Moderate help required	Minimal help required	fully independent
Personal Hygiene	☐ 0	☐ 1	☐ 3	☐ 4	☐ 5
Bathing Self	☐ 0	☐ 1	☐ 3	☐ 4	☐ 5
Feeding	☐ 0	☐ 2	☐ 5	☐ 8	☐ 10
Toilet	☐ 0	☐ 2	☐ 5	☐ 8	☐ 10
stair Climbing	☐ 0	☐ 2	☐ 5	☐ 8	☐ 10
Dressing	☐ 0	☐ 2	☐ 5	☐ 8	☐ 10
Bowel Contrl	☐ 0	☐ 2	☐ 5	☐ 8	☐ 10
Bladder control	☐ 0	☐ 2	☐ 5	☐ 8	☐ 10
Chair/Bed transfers	☐ 0	☐ 3	☐ 8	☐ 12	☐ 15
ambulation or wheelchair	☐ 0	☐ 3	☐ 8	☐ 12	☐ 15
	☐ 0	☐ 1	☐ 3	☐ 4	☐ 5

MBI Total Score Dependency Level	
0-24	☐ Total
24-49	☐ Severe
50-74	☐ Moderate
75-90	☐ Mild
91-99	☐ Minimal

Total Score : 점

Comment :

부록 3. Modified Rankin Scale(mRS)

Modified Rankin Scale (Inpatient)							
Registration Number		Name		Sex		Age	

Score	Description
☐ 0	No symptoms at all
☐ 1	No significant disability despite symptoms; able to carry out all usual duties and activities
☐ 2	Slight disability; unable to catty out all previous activities but also to look after own affairs without assistance
☐ 3	Moderate disability; requiring some help but able to walk without assistance
☐ 4	Moderately severe disability; unable to walk without assistance and unable to attend to own bodily needs without assistance
☐ 5	Severe disability; bedridden, incontinent and requiring constant nursing care and attention
☐ 6	Dead

TOTAL (0-6) : _____

부록 4. Korean-National Institute of Health Stroke Scale(NIHSS)

Korean-National Institute of Health Stroke Scale							
Registration Number		Name		Sex		Age	

Instructions	Scale definition	Scoring
1a-Level of consciousness	0=Alert; keenly responsive 1=Not alert, but arousable my minor stimultion 2=Not alert; requires repeated stimulation 3=Unresponsive or responds only with reflex	
1b-Level of consciousness questions: What is your age? What is the month?	0=Answers two questions correctly 1=Answers one question correctly 2=Answers neither questions correctly	
1c-Level of consciousness commands: Open and close your eyes Grip and relese your hand	0=Performs both tasks correctly 1=Performs one task correctly 2=Performs neither task correctly	
2-Best gaze	0=Normal 1=Partial gaze palsy 2=Forced deviation	
3-Visual	0=No visual lost 1=Partial hemianopia 2=Complete hemianopia 3=Bilateral hemianopia	
4-Facial palsy	0=Normal symmetric movements 1=Minor paralysis 2=Partial paralysis 3=Complete paralysis of one or both sides	
5-Motor arm	0=No drift	

Left arm Right are	1=Drift 2=Some effort against gravity 3=No effort against gravity 4=No movement	
6-Motor leg Left leg Right leg	0=No drift 1=Drift 2=Some effort against gravity 3=No effort against gravity 4=No movement	
7-Limb ataxiz	0=Absent 1=Present in one limb 2=Present in two limb	
8-Sensory	0=Normal; no sensory loss 1=Mild-to-moderate sensory loss 2=Severe-to-total sensory loss	
9-Best language	0=No aphasia; normal 1=Mild-to-moderate aphasia 2=Severe aphasia 3=Mute; global aphasia	
10-Dysarthria	0=Normal 1=Mild-to-moderate dysarthria 2=Severe dysarthria	
11-Extinction and inattention	0=No abnormality 1=Visual, tactile, auditory, spatial, or personal inattention 2=Profound hemi-inattention or extinction	
Score=0-42		